

认知科学与类脑计算

主讲教师：刘千惠

联系方式：qhliu@sdu.edu.cn

山东大学 人工智能学院



- M-P神经元
- 现代深度学习中的人工神经元
- 脉冲神经元

Hodgkin-Huxley模型

Leaky integrate-and-fire (LIF) 模型

- 基于突触输入的神经计算

- M-P神经元
- 现代深度学习中的人工神经元
- 脉冲神经元

Hodgkin-Huxley模型


Leaky integrate-and-fire (LIF) 模型

- 基于突触输入的神经计算


Hodgkin-Huxley模型




1952年由Alan Hodgkin和Andrew Huxley提出Hodgkin-Huxley模型，因为其在解释动作电位的产生和传播方面的奠基性贡献，两人在1963年被授予诺贝尔医学奖。原版的H-H模型是基于对乌贼的神经刺激电位数据总结得出，随后成为许多不同生理结构中的神经细胞的模型雏形。



Alan Hodgkin
(1914-1998)



Andrew Huxley
(1917-2012)



Hodgkin-Huxley模型



$$I_m = C_m \frac{dV_m}{dt} + \bar{g}_K n^4 (V_m - V_K) + \bar{g}_{Na} m^3 h (V_m - V_{Na}) + \bar{g}_l (V_m - V_l)$$

$$\frac{dn}{dt} = \alpha_n(V_m)(1 - n) - \beta_n(V_m)n$$

$$\frac{dm}{dt} = \alpha_m(V_m)(1 - m) - \beta_m(V_m)m$$

$$\frac{dh}{dt} = \alpha_h(V_m)(1 - h) - \beta_h(V_m)h$$

$$\alpha_n(V_m) = \frac{0.01(V_m + 55)}{1 - \exp(-(V_m + 55)/10)},$$

$$\beta_n(V_m) = 0.125 \exp(-(V_m + 65)/80)$$

$$\alpha_m(V_m) = \frac{0.1(V_m + 40)}{1 - \exp(-(V_m + 40)/10)},$$

$$\beta_m(V_m) = 4 \exp(-(V_m + 65)/18)$$

$$\alpha_h(V_m) = 0.07 \exp(-(V_m + 65)/20),$$

$$\beta_h(V_m) = \frac{1}{1 + \exp(-(V_m + 35)/10)}$$

Hodgkin-Huxley模型



$$I_m = C_m \frac{dV_m}{dt} + \bar{g}_K n^4 (V_m - V_K) + \bar{g}_{Na} m^3 h (V_m - V_{Na}) + \bar{g}_l (V_m - V_l)$$

$$\frac{dn}{dt} = \alpha_n(V_m)(1 - n) - \beta_n(V_m)n$$

$$\frac{dm}{dt} = \alpha_m(V_m)(1 - m) - \beta_m(V_m)m$$

$$\frac{dh}{dt} = \alpha_h(V_m)(1 - h) - \beta_h(V_m)h$$

$$\alpha_n(V_m) = \frac{0.01(V_m + 55)}{1 - \exp(-(V_m + 55)/10)},$$

$$\beta_n(V_m) = 0.125 \exp(-(V_m + 65)/80)$$

$$\alpha_m(V_m) = \frac{0.1(V_m + 40)}{1 - \exp(-(V_m + 40)/10)},$$

$$\beta_m(V_m) = 4 \exp(-(V_m + 65)/18)$$

$$\alpha_h(V_m) = 0.07 \exp(-(V_m + 65)/20),$$


$$\beta_h(V_m) = \frac{1}{1 + \exp(-(V_m + 35)/10)}$$

Hodgkin-Huxley模型



$$I_m = C_m \frac{dV_m}{dt} + \bar{g}_K n^4 (V_m - V_K) + \bar{g}_{Na} m^3 h (V_m - V_{Na}) + \bar{g}_l (V_m - V_l)$$

$$I_m = I_C + I_{Na} + I_K + I_l$$



Hodgkin-Huxley模型



$$I_m = C_m \frac{dV_m}{dt} + \bar{g}_K n^4 (V_m - V_K) + \bar{g}_{Na} m^3 h (V_m - V_{Na}) + \bar{g}_l (V_m - V_l)$$

$$I_m = I_C + I_{Na} + I_K + I_l$$

根据电容量的定义 $C = Q/V$ (其中 Q 是电荷, V 是电压), 我们得到电容电流:

$$I_C = dQ/dt = C dV/dt$$

Hodgkin-Huxley模型



$$I_m = C_m \frac{dV_m}{dt} + \bar{g}_K n^4 (V_m - V_K) + \bar{g}_{Na} m^3 h (V_m - V_{Na}) + \bar{g}_l (V_m - V_l)$$

$$I_m = C_m \frac{dV_m}{dt} + I_{Na} + I_K + I_l$$

$$I_{ion} = g_{ion} (V_m - V_{ion})$$

Hodgkin-Huxley模型



$$I_m = C_m \frac{dV_m}{dt} + \bar{g}_K n^4 (V_m - V_K) + \bar{g}_{Na} m^3 h (V_m - V_{Na}) + \bar{g}_l (V_m - V_l)$$

$$I_m = C_m \frac{dV_m}{dt} + I_{Na} + I_K + I_l$$

$$I_{ion} = g_{ion} (V_m - V_{ion})$$

$$I_{ion} = \bar{g}_{ion} p (V_m - V_{ion})$$

所有离子通道开放时达到的最大电导

$p \in [0,1]$ 任意时刻开放离子通道的比例

$$I_K = \bar{g}_K n^4 (V_m - V_K) \quad I_{Na} = \bar{g}_{Na} m^3 h (V_m - V_{Na})$$

Hodgkin-Huxley模型



$$I_m = C_m \frac{dV_m}{dt} + \bar{g}_K n^4 (V_m - V_K) + \bar{g}_{Na} m^3 h (V_m - V_{Na}) + \bar{g}_l (V_m - V_l)$$

$$\begin{aligned}\frac{dn}{dt} &= \alpha_n(V_m)(1 - n) - \beta_n(V_m)n \\ \frac{dm}{dt} &= \alpha_m(V_m)(1 - m) - \beta_m(V_m)m \\ \frac{dh}{dt} &= \alpha_h(V_m)(1 - h) - \beta_h(V_m)h\end{aligned}$$

$$\alpha_n(V_m) = \frac{0.01(V_m + 55)}{1 - \exp(-(V_m + 55)/10)},$$

$$\beta_n(V_m) = 0.125 \exp(-(V_m + 65)/80)$$

$$\alpha_m(V_m) = \frac{0.1(V_m + 40)}{1 - \exp(-(V_m + 40)/10)},$$

$$\beta_m(V_m) = 4 \exp(-(V_m + 65)/18)$$


$$\alpha_h(V_m) = 0.07 \exp(-(V_m + 65)/20),$$

$$\beta_h(V_m) = \frac{1}{1 + \exp(-(V_m + 35)/10)}$$

Hodgkin-Huxley模型



$$\begin{aligned}\frac{dn}{dt} &= \alpha_n(V_m)(1 - n) - \beta_n(V_m)n \\ \frac{dm}{dt} &= \alpha_m(V_m)(1 - m) - \beta_m(V_m)m \\ \frac{dh}{dt} &= \alpha_h(V_m)(1 - h) - \beta_h(V_m)h\end{aligned}$$



打开速率 α ，关闭速率 β

Hodgkin-Huxley模型



$$I_m = C_m \frac{dV_m}{dt} + \bar{g}_K n^4 (V_m - V_K) + \bar{g}_{Na} m^3 h (V_m - V_{Na}) + \bar{g}_l (V_m - V_l)$$

$$\frac{dn}{dt} = \alpha_n(V_m)(1 - n) - \beta_n(V_m)n$$

$$\frac{dm}{dt} = \alpha_m(V_m)(1 - m) - \beta_m(V_m)m$$

$$\frac{dh}{dt} = \alpha_h(V_m)(1 - h) - \beta_h(V_m)h$$

$$\alpha_n(V_m) = \frac{0.01(V_m + 55)}{1 - \exp(-(V_m + 55)/10)},$$

$$\beta_n(V_m) = 0.125 \exp(-(V_m + 65)/80)$$

$$\alpha_m(V_m) = \frac{0.1(V_m + 40)}{1 - \exp(-(V_m + 40)/10)},$$

$$\beta_m(V_m) = 4 \exp(-(V_m + 65)/18)$$

$$\alpha_h(V_m) = 0.07 \exp(-(V_m + 65)/20),$$


$$\beta_h(V_m) = \frac{1}{1 + \exp(-(V_m + 35)/10)}$$

Hodgkin-Huxley模型




山东大学
SHANDONG UNIVERSITY


A




C



B



An action potential in the Hodgkin-Huxley equations



- M-P神经元
- 现代深度学习中的人工神经元
- 脉冲神经元

Hodgkin-Huxley模型

Leaky integrate-and-fire (LIF) 模型

- 基于突触输入的神经计算

- LIF模型起源于 1907 年 Louis Lapicque提出的积分发放模型，Tuckwell在1988年系统发展并推广了带 leak 的 LIF 模型。
- 与HH模型的区别在于LIF神经元把所有跨膜电阻成分看做一个整体，并假设它是不变的，这样就将模型大大化简了。
- 该模型利用了一个事实，即给定神经元的动作电位通常具有大致相同的形式。如果动作电位的形状始终不变，那么形状就不能用于传递信息，信息包含在脉冲出现的时间和数量中。因此动作电位被还原为发生在精确时刻的“事件”。

$$I(t) = I_R + I_C$$

其中:


$$I_R = u_R / R = (u(t) - u_{rest}) / R$$

$$I_C = dq/dt = C du/dt$$

$$I(t) = \frac{u(t) - u_{rest}}{R} + C \frac{du}{dt}$$

乘以 R ，并引入膜时间常数 $\tau_m = RC$ ，
即可得到LIF神经元的标准形式

$$\tau_m \frac{du}{dt} = -(u(t) - u_{rest}) + RI(t)$$



- Leaky Integrate and Fire (LIF) 动力学方程:

$$\tau_m \frac{du(t)}{dt} = -[u(t) - u_{rest}] + R_m I(t)$$

τ_m : Membrane time constant

$u(t)$: Membrane potential

u_{rest} : Resting potential

R_m : Membrane resistance

$I(t)$: Total input current

利用电流守恒定律，驱动电流 $I(t)$ 可分为两个部分：

$$I(t) = I_R + I_C \quad (1)$$

其中， I_R 是电阻电流：

$$I_R = \frac{u_R}{R} = \frac{(u(t) - u_{rest})}{R} \quad (2)$$

u_R 指的是穿过电阻上的电压， $u(t)$ 是 t 时刻膜电压， u_{rest} 是静息电压。

I_C 是对电容 C ($C = \frac{q}{u}$ ， q 为充电电荷， u 是电压) 进行充电，

$$I_C = \frac{dq}{dt} = \frac{d(Cu)}{dt} = C \frac{du}{dt} \quad (3)$$

所以，将(2)(3)代入(1)有：

$$I(t) = \frac{(u(t) - u_{rest})}{R} + C \frac{du}{dt} \quad (4)$$

等式(4)两边同时乘以 R , 有:

$$RI(t) = (u(t) - u_{rest}) + RC \frac{du}{dt} \quad (5)$$

令 $\tau_m = RC$, 则由(5)可得膜内外电压变化为:

$$\tau_m \frac{du}{dt} = -(u(t) - u_{rest}) + RI(t) \quad (6)$$

当输入恒定电流 I 时, (6)式可写为:

if $I(t)=I$, a constant input current

$$\frac{du}{dt} + \frac{1}{\tau_m} u(t) = \frac{1}{\tau_m} RI + \frac{1}{\tau_m} u_{rest} \quad (7)$$

对 $\frac{du}{dt} + \frac{1}{\tau_m} u(t) = 0$ 采用变量分离法:

$$u(t) = ce^{-\int P(t)dt} = ce^{-\int \frac{1}{\tau_m} dt} = ce^{-\frac{t}{\tau_m}} \quad (8)$$

对(8)采用常数变易法:

$$u(t) = c(t)e^{-\frac{t}{\tau_m}} \quad (9)$$

将(9)两边求微分:

$$\frac{du}{dt} = \frac{dc}{dt}e^{-\frac{t}{\tau_m}} - \frac{1}{\tau_m}c(t)e^{-\frac{t}{\tau_m}} \quad (10)$$

将(9)(10)代入(7)可得:

$$\frac{dc}{dt} = \frac{1}{\tau_m}RIe^{\frac{t}{\tau_m}} + \frac{1}{\tau_m}u_{rest}e^{\frac{t}{\tau_m}}$$

两边积分有:

$$c(t) = (RI + u_{rest})e^{\frac{t}{\tau_m}} + c_1$$

代入(9)可得:

$$u(t) = RI + u_{rest} + c_1e^{-\frac{t}{\tau_m}} \quad (11)$$

因为当 $t=0$ 时, $u(0) = RI + u_{rest} + c_1$, 所以, $c_1 = u(0) - (RI + u_{rest})$, 则方程(6)解析解:


$$u(t) = RI + u_{rest} + (u(0) - RI - u_{rest})e^{-\frac{t}{\tau_m}} \quad (12)$$

假设 $u(0) = u_{rest} = 0$,

$$u(t) = RI \left(1 - e^{-\frac{t}{\tau_m}} \right) \quad (13)$$

$$u(t) = RI + u_{rest} + (u(0) - RI - u_{rest})e^{-\frac{t}{\tau_m}}$$

如果, $u_{rest} = 0$, $I = 0$:



In absence of input, the membrane potential will start at $U_{mem}=U_0$ and exponentially decay with a time constant $\tau=RC$

在LIF模型中，我们更关心脉冲的发放时刻而非其形状。

若输入电流为恒定值 I ，脉冲的发放周期 T （忽略不应期的影响）可以表示为：

$$T = \tau_m \ln \frac{RI}{RI - V_{th}}$$

若考虑绝对不应期，则发放周期为：

$$T = \Delta_{abs} + \tau_m \ln \frac{RI}{RI - V_{th}}$$

由周期与频率的关系，可以计算出神经元的平均发放速率：


$$f = \frac{1}{T}$$

对于恒定的输入电流，脉冲的发放周期 $T = \tau_m \ln \frac{RI}{RI - V_{th}}$

(没有考虑不应期)


考虑不应期时 $T = \Delta_{abs} + \tau_m \ln \frac{RI}{RI - V_{th}}$

神经元的平均发放速率 $f = 1/T$




因为 $u_{thr} = 15\text{mV}$, $R = 1\text{m}\Omega$, 对于恒定的输入电流刺激, 当 $RI < u_{thr}$ 时, 不会发放脉冲。

在恒定电流驱动下LIF模型的膜电位轨迹



周期电流输入下LIF模型膜电位的变化曲线



其他脉冲神经元

- Izhikevich模型：由 Eugene M. Izhikevich 在 2003 年提出，是具有生物合理性的H-H模型与计算高效的LIF模型之间的折中。
- Adaptive exponential integrate-and-fire (AdEx) 模型：由 Romain Brette 和 Wulfram Gerstner 于 2005 年提出，在 LIF 中加入指数项和适应机制，既保持简洁又能精确拟合真实神经元放电行为。
- Compartmental neuron model多区室模型：将神经元划分为多个电缆式区室（树突、胞体等）进行建模，生物细节真实但计算开销很大。
- Stochastic模型：在神经元模型中引入随机噪声或概率发放机制，用于刻画真实神经系统的不确定性与变异性。

- M-P神经元
- 现代深度学习中的人工神经元
- 脉冲神经元

Hodgkin-Huxley模型

Leaky integrate-and-fire (LIF) 模型


- 基于突触输入的神经计算

为了更高效地模拟神经计算过程，我们对神经元之间的连接与信息传递机制进行了若干简化：

（1）时间窗近似：引入时间窗的概念，用于刻画神经元脉冲发放的时刻；忽略轴突上脉冲的动态传导过程，简化为时间窗口中某一静态时刻的发放事件。

（2）突触权重表示：用权重参数表示突触传递效率，并通过权重的调整来实现突触学习规则，从而刻画突触前后神经元连接关系的增强或者减弱。

(3) 电流与阈值机制：输入电流定义为同一时间内所有突触前神经元输入电流的总和；当没有输入电流时，膜电压逐渐衰减至零；当膜电压超过阈值时，触发动作电位，并在绝对不应期内将电压清零。



Postsynaptic potential (PSP)

$$u_i(t) - u_{rest} =: \epsilon_{ij}(t)$$

- $u_i(t)$ is the membrane potential of neuron i
- Positive: excitatory postsynaptic potential (EPSP)
- Negative: inhibitory postsynaptic potential (IPSP)

Action potential

- propagate along the axon of neuron i to the synapses of other neurons


$$u_i(t) = \sum_j \sum_f \epsilon_{ij} (t - t_j^{(f)}) + u_{rest}$$

- $t_j^{(f)}$ is the moment of neuron j firing spike


Firing threshold

- If $u_i(t)$ reaches threshold ϑ from below we say that neuron i fires a spike.


A



B






C





- 定义神经元 i 的膜电压为 $u_i(t)$ ，其静息态膜电压为 u_{rest} ；
- $t = 0$, 突触前神经元 j 发放一个脉冲, $t > 0$ 突触后电位 (PSP)

$$\varepsilon_{ij}(t) = u_i(t) - u_{rest}$$

- 如果PSP是正的，定义为兴奋型（Excitatory PSP），简称EPSP；
反之定义为抑制型（Inhibitory PSP），简称IPSP。



EPSP示意图



□ 分别定义突触前神经元 j , $j = 1, 2 \dots$, 和突触后神经元 i ;



□ 突触前神经元 j 发放的脉冲为

$t_j^f : t_j^1, t_j^2, \dots$, 突触后膜电压计算公式:

$$u_i(t) = \sum_j \sum_f \epsilon_{ij} \left(t - t_j^{(f)} \right) + u_{rest}$$

□ 膜电压对输入脉冲产生线性相应。

- 当膜电压超过一个关键值，定义为神经元的阈值 θ ，神经元发放一个动作电位AP，沿着神经元 i 的突触传递到其他神经元。





$t_j^{(f)}$ is the moment of neuron j firing spike

Action potential propagate along the axon of neuron i to the synapses of other neurons

通过突触前神经元的电流刺激

输入电流等于同一时间内所有突触前神经元输入电流的和。当没有电流时，电压会逐步泄漏至零。当电压超过阈值时，产生一个动作电位并在绝对不应期内将电压清零。



突触前神经元的输入激励

总的突触后电流表示为：
$$I(t) = \sum_j W_j \sum_f \alpha(t - t_j^{(f)})$$

$t_j^{(f)}$ 表示第j个突触前神经元的第f个脉冲的时间


$\alpha(t - t_j^{(f)})$ 表示突触后神经元在这个时间过程内能感受到电流

α 常见的形式： (1) $\alpha(t) = \alpha \frac{t}{\tau} \exp(1 - \frac{t}{\tau})$


(2) $\alpha(t) = \beta \frac{\tau_1}{\tau_2 - \tau_1} [\exp(-\frac{t}{\tau_1}) - \exp(-\frac{t}{\tau_2})]$

$\beta \frac{\tau_1}{\tau_2 - \tau_1}$ 用于将 α 核函数规范化为1，一般 α 核函数的最大值为1

- (a) $\tau = 20\text{ms}$ 时的单指数核函数随时间变化曲线；
(b) $\tau_1 = 50\text{ms}$, $\tau_2 = 10\text{ms}$ 时的双指数核函数随时间变化曲线。



(a)



(b)

考虑afferent inputs的LIF神经元仿真

- Leaky Integrate and Fire(LIF)

$$\tau_m \frac{du(t)}{dt} = -[u(t) - u_{rest}] + R_m I(t)$$

$$I(t) = \sum_j w_{ij} \sum_f \alpha(t - t_j^f)$$

$$\alpha(t - t_j^f) = \exp\left(-\frac{t - t_j^f}{\tau_m}\right)$$

τ_m : Membrane time constant

$u(t)$: Membrane potential

u_{rest} : Resting potential

R_m : Membrane resistance

$I(t)$: Total input current

w_{ij} : The synapse weight between presynaptic neuron j and postsynaptic neuron i

$\alpha(t - t_j^f)$: Kernel function, representing postsynaptic current (or PSP)

t : Current time


t_j^f : Spike time

考虑突触电流动力学的公式

$$\tau_m \frac{du(t)}{dt} = -[u(t) - u_{rest}] + R_m I(t)$$

$$\text{总的突触后电流: } I(t) = \sum_j w_{ij} \sum_f \alpha(t - t_j^f)$$

- w_{ij} : 突触前的神经元j和突触后的神经元i之间的突触权重
- $\alpha(t - t_j^f)$: 突触后神经元电流变化的核函数
- t : 当前时间点
- t_j^f : 表示第j个突触前神经元的第f个脉冲的时间




在现实生活中，外界信息大多是连续的，这与脉冲神经元离散的脉冲式信息处理方式存在一定差异。针对这种情况，可以采用基于神经元频率编码的方式：通过泊松编码方法，将原本取值于0-1区间的连续信号转变为发放次数服从泊松分布的脉冲序列，从而实现输入信号的仿真。

$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$$

泊松脉冲序列在时间 T 内的期望发放脉冲数为 λT 。在实际实现中，只需在每个时间步按照设定的发放概率独立生成脉冲即可。随着脉冲时间窗的增大，脉冲的平均发放频率会逐渐逼近设定的频率值。

输出神经元对脉冲输入模式的响应，输入脉冲密集的地方电压上升快，没有输入时电压逐渐下降。



□ 假设某神经元参数如下，用LIF模型计算该神经元的脉冲发放频率。

$$I = 20 \text{ mA}$$

$$R = 1 \text{ m}\Omega$$

$$u_{thr} = 10 \text{ mV}$$

$$\tau_m = 10 \text{ ms}$$

□ 推导出LIF神经元的动力学方程；

$$I(t) = I_R + I_C$$

$$\tau_m \frac{du(t)}{dt} = -[u(t) - u_{rest}] + R_m I(t)$$

τ_m : Membrane time constant

$u(t)$: Membrane potential

u_{rest} : Resting potential

R_m : Membrane resistance

$I(t)$: Total input current

在LIF模型中，我们更关心脉冲的发放时刻而非其形状。

若输入电流为恒定值 I ，脉冲的发放周期 T （忽略不应期的影响）可以表示为：

$$T = \tau_m \ln \frac{RI}{RI - V_{th}}$$

若考虑绝对不应期，则发放周期为：

$$T = \Delta_{abs} + \tau_m \ln \frac{RI}{RI - V_{th}}$$

由周期与频率的关系，可以计算出神经元的平均发放速率：

$$f = \frac{1}{T}$$