

认知科学与类脑计算

主讲教师：刘千惠


联系方式：qhliu@sdu.edu.cn

山东大学 人工智能学院



- 突触可塑性
- 短期突触可塑性
- 长期突触可塑性
 1. 长期突触增强
 2. 长期突触抑制
 3. 同/异质突触可塑性
 4. 稳态可塑性
 5. 赫布规则 (Hebbian Rule)
 6. 脉冲时序依赖可塑性 (Spike-timing-dependent plasticity, STDP)

突触可塑性是神经元的一项基本特征，其指的是神经元可以通过多种依赖活动的机制来实现对突触强度的控制，因此突触传递强度可随活动变化而**增强**或**减弱**。



突触强度如何改变？


- 通过调整**突触前神经递质的释放量**来改变突触连接强度；
- 通过调整**突触后受体的可用数量**来改变突触连接强度；


突触可塑性均与**突触后钙离子动态密切相关**。根据持续时间不同，突触可塑性可分为**短期突触可塑性**和**长期突触可塑性**。

短期突触可塑性主要由突触前脉冲序列的相关性驱动，即依赖于输入信号的时间结构。而**经典的长期突触可塑性**是由**突触前和突触后活动之间的相互作用和相关性驱动的**，强调神经元之间的交互作用。

当突触短时间内接受快速且重复的刺激时，其传递效能会显著增强，并且这种增强能够持续较长时间。这一突触强度的持久提升现象被称为**长期突触增强（Long-Term Potentiation, LTP）**。与之相对的是，突触效能也可能在长时间尺度上逐渐减弱，这一现象被称为**长期突触抑制（Long-Term Depression, LTD）**。

长期突触增强具体描述的是：在电刺激诱发动作电位脉冲之后，突触反应水平出现持续性增强，其效能可维持数小时甚至更久，并显著高于基线水平。






- 在LTP过程中，AMPA受体的活化引发大量钠离子（ Na^+ ）内流，从而导致突触后膜急剧去极化，产生兴奋性突触后电位。
- 去极化进一步解除NMDA受体上的镁离子阻塞，使其得以开放，允许钙离子和谷氨酸分子进入细胞内。
- 随着细胞内钙离子（ Ca^{2+} ）浓度的升高，钙/钙调蛋白依赖性蛋白激酶II（CaMKII）和蛋白激酶C（PKC）等关键蛋白激酶增加突触后神经元中的AMPA受体数量和活性，进一步增强了突触传递的效率。

同质突触可塑性具有明显的输入特异性。


异质突触可塑性改变自身和其他未被直接激活的连接的突触强度。




海马CA1区的同突触长期增强现象

输入1的刺激（箭头所示）导致了
对该输入刺激的增强反应

EPSP
magnitude in
response to
test stimulation
of input 1




EPSP
magnitude in
response to
test stimulation
of input 2




在输入1接受刺激后，输入2的反应没有变化。

神经元能够通过稳态突触可塑性调节其所有兴奋性突触的强度，从而稳定脉冲发放率。稳态可塑性的主要功能是对长期活动水平的变化进行补偿，使神经元的放电频率维持在一个动态的生理范围，避免因突触效能过度增强而导致的失控。



若突触前神经元A的轴突与突触后神经元B足够接近，并能够反复或持续地刺激神经元 B，使其产生脉冲发放，那么从神经元 A 的到神经元 B 的突触效能便会增强。

概括为“一起发放的细胞会连接在一起”。



然而，Hebb也指出，细胞A必须“参与触发”细胞B，只有当细胞A的活动先于细胞B的发放，而并非同时发生时，这种因果关系才能成立。对这一因果关系的深入研究，后来发展为脉冲时序依赖可塑性（Spike-Timing Dependent Plasticity, STDP）。


- 脉冲时序依赖可塑性 (Spike-timing-dependent plasticity, **STDP**) 对由突触前、突触后膜电位驱动的脉冲发放精确时间极为敏感，其关注的并非脉冲发放率，而是**网络活动的精细时序特征**。
- 脉冲时序依赖可塑性是一种根据大脑神经元间**输入与输出脉冲的相对时间关系来调节突触强度的生物过程**。它揭示了部分依赖发放活动的突触权重调整机制，尤其可以解释长期突触增强和长期突触抑制的发生。

脉冲时序依赖可塑性 (STDP)




山东大学
SHANDONG UNIVERSITY

当突触前脉冲先于突触后脉冲时，突触权重会增加，表现为长期增强；反之，当突触后脉冲先于突触前脉冲时，突触权重则减弱，表现为长时抑制。





STDP也存在很多变体，常见的四种形式包括：

- 均衡型Hebb STDP，指长期增强与长期抑制作用基本对称；
- 偏抑制型 Hebb STDP，指长期抑制效应更为显著；
- 不均衡型逆Hebb STDP，指同时包含不对称的长期增强与长期抑制；
- 纯抑制型逆Hebb STDP，即只包含长期抑制。



- 突触权重/效能 (synaptic weight/ efficacy): 神经网络中, 从神经元 j 到 i 的突触连接由权重参数 w_{ij} 表示, 该参数决定了传入动作电位 (action potential) 的突触后响应幅度, 可以调整以优化给定任务的网络性能。
- 学习&学习规则:
 - ✓ 参数自适应过程称为学习;
 - ✓ 调整权重的过程称为学习规则。




神经元模型与计算机制

- M-P神经元和**Perception**单层感知机
- 现代深度学习中的人工神经元和**MLP**多层感知机
- 脉冲神经元和**脉冲神经网络**
- 基于突触输入的神经计算

Perception单层感知机




Perceptron，也被称为单层感知机，由Frank Rosenblatt在1957年提出，通常由两层神经元组成，输入层接收外界输入信号后传递给输出层，输出层是M-P神经元。单层感知机模型是一个二分类线性分类器，它使用一层具有可调权重的神经元来处理输入数据。





感知机所处理的任务建立在一个关键的前提条件之上，即训练数据集的线性可分性。

线性分类器




非线性分类器



Perception单层感知机



- 神经元输入 $x_1, x_2, \dots, x_n$ ，对应的权重 $w_1, w_2, \dots, w_n$ 。神经元计算这些加权输入的总和，并生成输出 y 。
- 误差 E 通常是输出值 y 与目标值 d 之差，学习就是通过不断调整权重来减少误差，以此优化神经网络的性能。



假设有 N 维的特征输入 $X=\{x_1, x_2, \dots, x_n\}$ ，输出的类别有两类



$Y=\{+1, -1\}$ ，则由特征输入映射到类别输出的函数

$$f(x)=\text{sign}(w \cdot x + b)$$

称为感知机模型，其中， w 和 b 是我们要求解的模型的参数，这里的 w 其实是一个跟特征输入维度一样 N 维的权值向量（也称为权重），而参数 b 为偏置（在二维平面上， b 就是截距）。

为什么说感知机模型是一个线性二分类模型？

先看符号函数里面的线性方程 $y = w \cdot x + b$ 方程在二维平面上是一条直线，在三维空间上是一个平面，在四维甚至更高维空间上就是一个超平面。




再看符号函数，定义如下：

$$\text{sign}(x) = \begin{cases} +1, & x \geq 0 \\ -1, & x < 0 \end{cases}$$


对于函数 $f(x)=\text{sign}(w \cdot x + b)$ ，如果输入样本 $w \cdot x + b \geq 0$ ，那么该样本会被判为+1类，否则判为-1类。

因此，感知机模型是一个线性二分类模型，其任务就是，找到这样的一个超平面，能够把两个不同的分类完全分割开。

给定一个包含正负类的训练样本，我们应该如何找出这样的一个超平面，使之能够将正样例和负样例点完全分割开，也就是应该如何确定模型的参数 w 和 b ？




直接求解好像无从下手，不妨先假设参数 w 和 b 已知，也就是说这个超平面 S 我们已经找到了，但是不知道这超平面对数据的分类效果怎样。



感知机的损失函数定义为误分类点到超平面的总距离。

一个点到一个平面的距离定义为：

$$d = \frac{1}{\|w\|} |w \cdot x_{(i)} + b| \quad \|w\| \text{为} w \text{的L2范数}$$



有了单个误分类点离超平面的距离，那么对于所有的误分类点有：

$$-\frac{1}{\|w\|} \sum_i^m y_i (w \cdot x_{(i)} + b)$$


其中m为误分类点数量。当不考虑 $\|w\|$ 时（ $\|w\|$ 恒大于0），就得到感知机模型的损失函数：

$$L(w, b) = - \sum_i^m y_i (w \cdot x_{(i)} + b)$$

损失函数的结果越小，分类效果越好。


对于任意一个样本点 $(x_{(i)}, y_{(i)})$:

- 如果该样本点位于直线上方，且属于类别A，那么该样本点被直线正确分类，此时有 $w * x_{(i)} + b > 0, y_i = +1$ ， $-y_{(i)} * (w * x_{(i)} + b) < 0$
- 如果该样本点位于直线下方，且属于类别B，那么该样本点被直线正确分类，此时有 $w * x_{(i)} + b < 0, y_i = -1$ ， $-y_{(i)} * (w * x_{(i)} + b) < 0$



对于任意一个样本点 $(x_{(i)}, y_{(i)})$:

- 如果该样本点位于直线上方，且属于类别B，那么该样本点被直线错误分类，此时有 $w * x_{(i)} + b > 0, y_i = -1, -y_{(i)} * (w * x_{(i)} + b) > 0$
- 如果该样本点位于直线下方，且属于类别A的话，那么该样本点被直线错误分类，此时有 $w * x_{(i)} + b < 0, y_i = +1, -y_{(i)} * (w * x_{(i)} + b) > 0$



我们可以将参数 w 和 b 的求解转化为最小化函数

$$\min L(w, b) = - \sum_i^m y_{(i)} * (w * x_{(i)} + b)$$

最优化方法有很多，这里使用最简单也最常用的随机梯度下降法。

梯度其实就是求偏导，随机梯度下降就是一次随机选一个误分类点，不断逼近最小值的一个过程。函数 $L(w, b)$ 关于参数 w 和 b 的梯度分别为：

$$\nabla_w L(w, b) = - \sum_i^m y_{(i)} x_{(i)}$$

$$\nabla_b L(w, b) = - \sum_i^m y_{(i)}$$

单层感知机学习算法



山东大学
SHANDONG UNIVERSITY

输入：训练数据集 $\mathcal{D} = \{(x_{(1)}, y_{(1)}), (x_{(2)}, y_{(2)}), \dots, (x_{(n)}, y_{(n)})\}$ ，其中 $x_{(i)} \in \mathcal{X} = \mathcal{R}^n, y_{(i)} \in \mathcal{Y} = \{+1, -1\}, i = 1, 2, \dots, N$ ；学习率 $\eta (0 < \eta \leq 1)$ ；

输出：权重向量 w ；偏置 b ；感知机模型 $f(x) = \text{sign}(w \cdot x + b)$ 。

算法步骤：

初始化：选取初值 w_0, b_0

循环训练：

在训练集中选取一个样本 $(x_{(i)}, y_{(i)})$ ；


计算分类结果 $y_{(i)} (w \cdot x_{(i)} + b)$ ；

如果误分类（即 $y_{(i)} (w \cdot x_{(i)} + b) \leq 0$ ），更新权重和偏置：


$$w \leftarrow w + \eta y_{(i)} x_{(i)} \quad \text{控制平面旋转}$$

$$b \leftarrow b + \eta y_{(i)} \quad \text{控制平面平移}$$

重复上述步骤，直至训练集中没有误分类点。



选取不同的初始值(w, b)或者不同的误分类点, 划分的超平面很有可能会不一样, 这也就是为什么在线性可分数据集中, 用感知机模型求出来的解有无穷多个。如下面直线A,B,C都可作为解。



这种学习算法直观上有如下解释：当一个实例点被误分类，即位于分离超平面的错误一侧时，则调整 w, b 的值，使分离超平面向该误分类点的一侧移动，以减少该误分类点与超平面间的距离，直至超平面越过该误分类点使其被正确分类。

单层感知机的学习算法基于输入数据和期望输出之间的差异。如果感知机的输出与期望输出不符，它就会对权重进行调整，以减小这种差异。这个过程被重复进行，直到感知机在训练数据上表现得足够好或达到预定的迭代次数。这种学习方法使得感知机能够处理具有线性可分性的数据集。


Perceptron只能处理简单的分类任务，无法处理线性不可分的逻辑问题，因此在更复杂的维度上无法模拟大脑的逻辑运算。随着神经网络研究的发展，人们逐渐认识到单层感知机的局限性，开始探索更复杂的模型，即能够处理线性不可分问题的多层感知机模型（Multilayer Perceptron, MLP）。

虽然感知机在处理复杂问题时有限制，但对于神经网络和机器学习的发展起到了重要的推动作用，为后来更复杂的神经网络模型，如多层感知机和深度学习模型奠定了基础。

- M-P神经元和**Perception**单层感知机
- 现代深度学习中的人工神经元和**MLP**多层感知机
- 脉冲神经元和**脉冲神经网络**
- 基于突触输入的神经计算

多层感知机引入了隐藏层，因此可以通过非线性激活函数处理更复杂的分类任务。多层感知机的出现标志着第二代人工神经网络的发展。Geoffrey Hinton及其他研究人员在 1980 年代对“反向传播算法”（Backpropagation）的研究进一步推动了多层感知机的发展，使得这些网络能够通过调整权重来学习复杂的非线性关系，从而大幅提升了神经网络处理复杂逻辑问题的能力。

多层感知机（Multilayer Perceptron, MLP）是单层感知机的扩展和改进，它通过引入一或多个隐藏层来克服单层感知机局限性。



单层感知机的数学模型可表示为：

$$y = f(\sum(w_i * x_i) + b)$$

其中 f 通常是阶跃函数，这限制了它只能解决线性可分的问题。相比之下，MLP的模型更为复杂：对于一个具有一个隐藏层的MLP，其数学表达式可以表示为：

$$y = f2\left(\sum\left(w_{jk} * f1(\sum(w_{ij} * x_i) + b_j)\right) + b_k\right)$$

其中 $f1$ 和 $f2$ 分别是隐藏层和输出层的激活函数，通常选用sigmoid、tanh或ReLU等非线性函数。这种结构使MLP能够近似模拟任意复杂的非线性映射，从而解决非线性可分的任务。

MLP的训练通常使用反向传播算法，该算法基于梯度下降原理，通过计算损失函数对各层权重的偏导数来更新权重：

$$w_{ij} = w_{ij} - \eta * \partial L / \partial w_{ij}$$

其中 η 是学习率， L 是损失函数。

MLP的主要优势在于其强大的表达能力和学习复杂模式的能力。

- 单层感知机只能形成简单的决策边界，而MLP可以创建复杂的非线性决策边界，使其适用于各种复杂的分类和回归任务。
- MLP引入了隐藏层的概念，这些隐藏层可以被视为自动特征提取器，能够学习输入数据的高级表示，这是单层感知机所不具备的。

多层感知机的训练依赖于反向传播算法（Back Propagating, BP）。BP算法的核心思路如下：利用前向传导公式，计算第 n 层输出值；计算输出值和实际值的残差；将残差梯度传递回第 $n - 1, n - 2, \dots, 2$ 层，并修正各层参数（误差逆传播）。

前向传播

在神经网络中，前向传播是最基本的计算过程，它描述了数据从输入层进入网络，经过一系列线性变换和非线性映射，逐层传递到输出层，最终生成预测结果的机制。

直观地说，前向传播相当于信息在网络中的“正向流动”：
输入层接收原始特征，隐藏层通过权重和偏置对信息进行加权组合并施加非线性变换，逐步抽取和重组特征，直到输出层产生对任务的预测结果。每一层的计算不仅依赖于当前层的参数（权重矩阵和偏置向量），还依赖于前一层的激活值，这种逐层依赖构成了深度神经网络的层级特征表达能力。

前向传播

设网络共有 L 层，输入为 $x \in R^d$ ， n_l 表示第 l 层的神经元（单元）个数，第 l 层的权重为 $W^{(l)} \in R^{n_l \times n_{l-1}}$ ，偏置为 $b^{(l)} \in R^{n_l}$ ，激活函数为 $\sigma(\cdot)$ ，则第 l 层的前向传播可描述如下：


$$\begin{aligned} z^{(l)} &= W^{(l)} a^{(l-1)} + b^{(l)}, \\ a^{(l)} &= \sigma(z^{(l)}), \end{aligned}$$

其中 $a^{(0)} = x$ 是输入， $z^{(l)}$ 是第 l 层的线性输出， $a^{(l)}$ 是该层的激活值。输出层的激活值 $a^{(L)}$ 即为网络的预测输出 $\hat{y}$ 。

前向传播

$$z^{(l)} = W^{(l)} a^{(l-1)} + b^{(l)},$$

$$a^{(l)} = \sigma(z^{(l)}),$$



前向传播

在分类任务中，输出层通常采用 softmax 函数将输出转化为概率分布：

$$\hat{y}_i = \frac{e^{z_i^{(L)}}}{\sum_j e^{z_j^{(L)}}},$$

其中 $\hat{y}_i$ 表示属于类别 i 的预测概率，分母中的求和确保所有类别的概率和为1。这种概率化的输出特别适合与交叉熵（Cross Entropy）损失函数结合使用，从而衡量模型预测分布与真实标签分布之间的差异。

前向传播

当前向传播得到预测输出 $\hat{y}$ 后，需要将其与真实标签 y 进行比较，定义并计算损失函数 $\mathcal{L}(\hat{y}, y)$ ，为反向传播提供优化的目标信号。

常见的损失函数包括交叉熵损失（用于分类任务）和均方误差（用于回归任务）。交叉熵损失定义为：

$$\mathcal{L}(\hat{y}, y) = -\sum_{i=1}^C y_i \log(\hat{y}_i),$$

其中 C 表示类别数， y_i 是样本在类别 i 上的真实分布（通常是 one-hot 向量）， $\hat{y}_i$ 是模型对类别 i 的预测概率。当模型的预测概率与真实标签一致时，损失值最小；当预测偏离真实分布时，损失值增大。

前向传播

均方误差损失定义为：

$$\mathcal{L}(\hat{y}, y) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

其中 n 表示样本数， y_i 是样本 i 上的真实值， $\hat{y}_i$ 是模型对样本 i 的预测概率。

反向传播


反向传播算法，也称为误差反传算法，是神经网络领域中一种广泛应用的学习方法。其核心理念是**通过调整网络的权重参数，来最小化网络实际输出与预期输出之间的误差**。这种算法在多层感知机和各种深度学习模型的训练过程中扮演着关键角色，尤其是在高效更新网络权重和偏置方面表现突出。

反向传播

反向传播算法**链式法则**，**从输出层开始，逆向遍历整个网络直至输入层**。在这个过程中，算法会保存计算某些参数梯度所需的中间变量（即偏导数），以便进行后续的参数更新。这种逆向传递误差信息的方式使得算法能够精确地评估每个参数对最终输出的影响，从而实现网络的有效学习和优化。

反向传播

从直观上理解，前向传播是“信息的正向流动”，而反向传播则是“误差的逆向流动”。在前向传播中，我们得到输出 $\hat{y}$ 并计算损失 $L(\hat{y}, y)$ 。接下来，反向传播要做的就是回答一个问题：每一层的参数在多大程度上影响了最终的损失？



反向传播

在输出层，误差项的计算通常可以直接由损失函数与输出层激活函数的性质推导得到。例如在分类任务中，当采用交叉熵损失函数并结合 softmax 作为输出层激活时，误差项具有非常简洁的形式：

$$\delta^{(L)} = \hat{y} - y$$

其中 $\delta^{(L)}$ 表示输出层的误差信号， $\hat{y}$ 是预测概率分布， y 是真实分布。这个误差反映了模型预测与真实答案的差距。

反向传播

对于隐藏层，误差信号会通过链式法则向前一层传播。第 l 层的误差可以表示为：

$$\delta^{(l)} = (W^{(l+1)})^T \delta^{(l+1)} \odot \sigma'(z^{(l)})$$

其中 $(W^{(l+1)})^T \delta^{(l+1)}$ 表示后层的误差经过权重反传到当前层， $\sigma'(z^{(l)})$ 则是激活函数的导数，用来调节误差的大小。这样一来，后层的误差就逐步传回到了输入端。

反向传播

当每层的误差信号 $\delta^{(l)}$ 已经求出之后，梯度的计算就十分直接了。权重和偏置的梯度分别为：

$$\frac{\partial \mathcal{L}}{\partial W^{(l)}} = \delta^{(l)} (a^{(l-1)})^\top$$

$$\frac{\partial \mathcal{L}}{\partial b^{(l)}} = \delta^{(l)}$$

这表明权重的更新不仅取决于当前层的误差，还取决于前一层的激活输出，而偏置的更新则完全由该层误差决定。

反向传播

反向传播算法的工作流程可以概括为“前向传播—误差计算—反向传播—参数更新”的循环。由于其高效性和准确性，反向传播算法已成为深度学习领域不可或缺的工具。

即便是非常深层的网络也能学习复杂的函数映射，从而在图像识别、语音识别和自然语言处理等多个领域取得显著成果。

该算法也存在一些局限性，例如在极深的网络中可能出现梯度消失或爆炸问题，这需要通过各种技术和策略来解决。尽管面临这些挑战，反向传播算法仍然是现代神经网络训练的基础。

训练算法

在每一次迭代中，首先需要对输入样本进行前向传播。输入数据 x 经由网络逐层传递，依次完成线性变换和非线性激活，最终在输出层生成预测结果 $\hat{y}$ 。随后，将预测结果与真实标签 y 进行比较，并计算损失函数 $L(\hat{y}, y)$ 。这一损失刻画了网络当前预测与目标之间的差距，它既是模型性能的衡量指标，也是参数优化的直接依据。

训练算法

在得到损失值后，进入反向传播阶段。通过链式法则，误差信号从输出层开始逐层向后传递，依次计算各层参数对损失函数的梯度。具体来说，输出层的误差信号由预测概率与真实分布的差值直接给出，隐藏层的误差则由后一层的误差经过权重矩阵反传并结合激活函数的导数得到。最终，每一层的权重和偏置都能得到对应的梯度 $\frac{\partial \mathcal{L}}{\partial w^{(l)}}$ 与 $\frac{\partial \mathcal{L}}{\partial b^{(l)}}$ 。这些梯度量化了参数在损失变化中的贡献，是后续更新的核心依据。

训练算法

最后一步是参数更新。利用优化算法（如梯度下降法、随机梯度下降 SGD、动量法或 Adam 等），网络根据计算得到的梯度来修正参数。例如，在最简单的梯度下降法中，更新规则为：

$$W^{(l)} \leftarrow W^{(l)} - \eta \frac{\partial \mathcal{L}}{\partial W^{(l)}},$$

$$b^{(l)} \leftarrow b^{(l)} - \eta \frac{\partial \mathcal{L}}{\partial b^{(l)}},$$

其中 η 称为学习率，用于控制每次参数更新的幅度。学习率过大可能导致训练不稳定，过小则会导致收敛过慢，因此往往需要结合实际情况动态调整。

训练算法

在实际训练中，通常采用小批量随机梯度下降（mini-batch SGD）。这种方式将训练数据集划分为多个小批次，每个批次独立完成一次“前向传播—反向传播—参数更新”的过程。这不仅能显著提升计算效率，还能在一定程度上缓解梯度估计中的方差问题，使模型更稳定地收敛。

神经网络的训练过程本质上是一个不断循环的优化过程：前向传播提供预测，反向传播提供梯度，参数更新推动学习，三者紧密配合，驱动模型逐步逼近最优性能。

训练算法

训练过程会持续多个 epoch，即整个训练集被完整使用一次所对应的迭代。在训练过程中，常常需要使用独立的验证集来评估模型在未见数据上的表现，以便监控过拟合风险。同时，学习率调整、正则化方法（如权重衰减、Dropout）以及早停策略（Early Stopping）等，都是提升训练效果与泛化能力的重要手段。

梯度消失和梯度爆炸

梯度消失是深层神经网络训练过程中常见的现象，表现为在误差反向传播过程中，靠近输入层的梯度值趋近于零，从而导致前层参数几乎不更新。这种现象直接影响模型的学习能力，使得网络无法有效捕捉深层次的抽象特征。

梯度消失和梯度爆炸

为缓解这一问题，可以使用非饱和激活函数，如ReLU（其导数为1或0），以减缓梯度的衰减趋势。同时，也可以采用批归一化（Batch Normalization）对每一层输出标准化，保持激活值在合适范围内。此外，合理的参数初始化策略也能在一定程度上缓解梯度消失问题。

梯度消失和梯度爆炸


梯度爆炸问题，即在反向传播过程中，梯度值不断累积放大，最终导致数值不稳定甚至溢出。这通常发生在深层网络中使用较大的权重初始值，或当激活函数导数大于1时，多个层之间的链式乘积在反向传播中被指数放大，造成梯度爆炸。训练中会表现为损失函数异常上升、参数更新为NaN、模型性能波动剧烈等问题。

梯度消失和梯度爆炸

解决梯度爆炸的方法主要包括：

- 对梯度进行截断（Gradient Clipping），即当梯度超过设定阈值时将其缩放；
- 采用更稳定的优化器（如RMSprop或Adam），自动调整梯度的尺度；
- 合理初始化权重，控制初始值的方差；
- 引入残差连接（Residual Connection），减少层间依赖，降低梯度累计风险。

尽管反向传播算法在数学上非常有效，但由于大脑学习过程并不依赖显式的误差反向传播，人工神经网络与生物大脑工作方式的联系变得越来越少。为了更好地模仿大脑的工作机制，Wolfgang Maass提出了第三代神经网络，即脉冲神经网络（Spiking Neural Networks, SNNs）。




脉冲神经网络（Spiking Neural Network, SNN），旨在弥合神经科学和机器学习之间的差距，使用最拟合生物神经元机制的模型来进行计算。

脉冲神经网络与目前流行的神经网络和机器学习方法有着根本上的不同。SNN 使用脉冲——这是一种发生在时间点上的离散事件——而非常见的连续值。每个峰值由代表生物过程的微分方程表示出来，其中最重要的是神经元的膜电位。本质上，一旦神经元达到了某一电位，脉冲就会出现，随后达到电位的神经元会被重置。

脉冲神经网络无监督学习和有监督学习：

- 无监督学习：使用**没有标签的数据**，让模型自己发现数据中的结构或规律。
- 有监督学习：使用**带标签的数据**进行训练，让模型学会从输入映射到输出。



- 大脑的无监督学习是一种通过感知环境、自主探索而发现信息内在规律的认知过程，是人类和动物认知的核心机制之一。
- 这种学习形式的关键特点是无需外部教师信号指导，而是通过观察和探索自主提取环境中的模式和规律。
- 无监督学习不仅帮助个体更有效地适应环境，还具有减少个体对外部资源依赖的优势，在资源效率和演化适应中发挥了重要作用。

- 什么是脉冲时序依赖可塑性（STDP），并画出突触改变随时间变化的示意图。
- 请写出有监督学习和无监督学习的区别。