

认知科学与类脑计算

主讲教师：刘千惠

联系方式：qhliu@sdu.edu.cn


山东大学 人工智能学院



脉冲神经网络的无监督学习

- Hebb学习规则
- STDP学习规则

- 大脑的无监督学习是一种通过感知环境、自主探索而发现信息内在规律的认知过程，是人类和动物认知的核心机制之一。
- 这种学习形式的关键特点是无需外部教师信号指导，而是通过观察和探索自主提取环境中的模式和规律。
- 无监督学习不仅帮助个体更有效地适应环境，还具有减少个体对外部资源依赖的优势，在资源效率和演化适应中发挥了重要作用。



仿照大脑无监督学习形式，脉冲神经网络也可以通过输入数据的内在结构和分布关系，在没有明确标注或“教师”信号的情况下，自适应调整神经网络中的连接权重或结构，进而从输入数据中发现规律和模式（如统计特征、相关性或类别等）。

不同于监督学习中实际与期望输出误差信号驱动的突触调整，无监督学习主要依赖于突触可塑性机制，这一机制使其具备良好的生物可解释性。

突触可塑性描述了突触权值变化的方式，在神经结构的发育、记忆和学习中扮演重要角色，其中最具代表性的是赫布学习规则与脉冲时间依赖可塑性（STDP）学习规则。

Hebb学习规则是一种基于神经元活动相关性的突触调整机制，不仅能够有效提取数据的统计特征和相关性，还可以解释记忆形成、习惯学习和感知适应等认知现象，为无监督学习算法的构造提供了重要的理论支撑。

STDP学习规则是 Hebb规则的时间依赖扩展形式，能更加精确地描述了突触可塑性与神经活动关系，并阐明突触强度变化与突触前后脉冲时序关系的基本理论。


脉冲神经网络的无监督学习

- Hebb学习规则
- STDP学习规则

在神经科学和联结主义理论中，赫布学习规则揭示了神经元集群通过同步激活形成功能联结的基本机制。


Hebb关于细胞集群的形式和功能给出了以下解释：任何两个同时以及重复处于活跃状态的细胞或细胞系统都会趋向于形成“关联”。

从神经网络的角度，当输入导致某种活动模式反复出现时，构成该模式的一组神经元关联会更加紧密。



在神经网络的形式理论中，从神经元 j 到 i 连接的权重 w_{ij} 被认为是一个可以适应调整的参数，其中，参数的调整过程称为学习，具体的调整方式称为学习规则。

Hebb 原理启发了一类由突触前后神经元的相关活动驱动突触权重变化的学习规则，被称为“**Hebb学习**”，为人工神经网络学习算法的研究奠定了理论基础。



基于脉冲频率的神经元模型中，神经元i的活动可以通过它的发放频率 v_i 来描述，发放频率可以表示为神经元膜电位 u_i 的函数：

$$v_i = g(u_i)$$

其中， g 是非线性单调递增函数，而膜电位 u_i 是突触前神经元j的发放频率 v_j 和突触权值 w_{ij} 加权和，即 $u_i = \sum_j w_{ij} v_j$

Hebb学习规则满足**局部特性**，即突触前神经元j和突触后神经元i之间的突触连接权值 w_{ij} 只依赖于这两个神经元之间的状态，与其他神经元无关。在脉冲频率模型中，**神经元i的状态完全由其脉冲发放频率 v_i 表征**。因此频率模型中突触权值的改变量可以表达为

$$\frac{dw_{ij}}{dt} = F(w_{ij}; v_i, v_j)$$

1) 标准的Hebb学习规则

在一般性框架式中仅考虑突触前和突触后活动的协同关系，参数 $c_2^{corr}(w_{ij})$ 为正的常量，得到标准形式为

$$\frac{dw_{ij}}{dt} = c_2^{corr}(w_{ij}) v_i v_j$$

协同性：突触前和突触后神经元必须同时活跃，才能发生突触权重变化。

Cells that fire together, wire together

1) 标准的Hebb学习规则+突触权重约束

$$\frac{dw_{ij}}{dt} = c_2^{corr}(w_{ij}) v_i v_j$$



$$c_2^{corr}(w_{ij}) = \gamma_2 (1 - w_{ij})$$

如果仅依赖协同性，
突触强度会无限增大！

突触权重饱和：

w_{ij} 不可独立于F，否则持续施加相同的增强刺激，权重会无限增长；需保证 w_{ij} 达到最大值（ $w_{\max}=1$ ）时， c_2^{corr} 趋近于0.

权重最终都会在最高值处饱和。

(2) 基于衰减的Hebb规则

最初Hebb学习不包含突触权重减少的规则，权重持续增大存在饱和的问题。因此，考虑到突触权值的衰减过程，可表示为：

$$\frac{dw_{ij}}{dt} = \gamma_2(1 - w_{ij})v_i v_j - \gamma_0 w_{ij}$$

γ_0 是较小正值，描述了在没有刺激的情况下突触衰减回零的速率。

突触权重“软”边界（soft bounds）：

- $w_{ij} = 1$ ：持续刺激时饱和；
- $w_{ij} = 0$ ：无刺激时指数衰减至0。

TIPs：突触权重“硬”边界（hard bounds）：将突触权重限制在有限的区间内，即，只有权重保持在其限制范围内，才应用具有权重无关参数（weight-independent parameters）的学习规则。

3) 突触前门控的Hebb规则


权重变化是由突触前神经元“门控”的，其形式为

$$\frac{dw_{ij}}{dt} = \gamma (v_i - v_\theta) v_j$$

该形式表明只有当突触前神经元活跃时($v_j > 0$)，突触权重才会发生变化，并且变化的方向由突触后神经元的活动决定。当突触后神经元高度活跃，即神经元活动速率超过门控阈值 v_θ ($v_i > v_\theta$)时突触增强，否则突触削弱。

突触前门控规则可以进一步推广为BCM规则（Bienenstock-Cooper-Munroe Rule），通过引入非线性函数 Φ ，并用平均输出速率 $\langle v_i \rangle$ 替代参考速率 v_θ ，其形式为

$$\frac{dw_{ij}}{dt} = \eta \Phi(v_i - v_\theta) v_j$$





Hebb数学模型



山东大学
SHANDONG UNIVERSITY

Initial:
random
connections



Correlated input

**BCM leads to specialized
Neurons (developmental learning);**
Bienenstock et al. 1982

Development and learning rules:
Willshaw & v.d. Malsburg, 1976
Linsker, 1986
K.D. Miller et al., 1989

Competition of synapses:
some grow while others decay

Hebb数学模型




山东大学
SHANDONG UNIVERSITY

Initial:
random
connections




**BCM leads to specialized
Neurons (developmental learning);**
Bienenstock et al. 1982

Development and learning rules:
Willshaw & v.d. Malsburg, 1976
Linsker, 1986
K.D. Miller et al., 1989



Correlated input



*output neurons specialize:
Receptive fields*

(4) 突触后门控的Hebb规则

与突触前门控Hebb学习规则相反，权重变化是由突触后神经元“门控”的，也就是只有当突触后神经元活跃时 $v_i > 0$ ，权重才会发生变化：其Hebb规则形式为

$$\frac{dw_{ij}}{dt} = \gamma v_i (v_j - v_\theta)$$

- ✓ 同突触长时程增强 (**homosynaptic LTP**): 高度活跃的突触前神经元与突触后神经元的连接突触权重LTP;
- ✓ 异突触长时程抑制 (**heterosynaptic LTD**): 其他未被激活的突触前神经元与突触后神经元的连接突触权重LTD。

实现了一种
竞争学习

(5) 协变规则

协变规则的形式为

$$\frac{dw_{ij}}{dt} = \gamma(v_i - \langle v_i \rangle)(v_j - \langle v_j \rangle)$$

其中 $\langle v_i \rangle$ 和 $\langle v_j \rangle$ 分别表示神经元输出频率 v_i 和 v_j 的短时程平均。

将速率 $v_i(t)$ 和 $v_j(t)$ 围绕平均发放率 $\langle v_i \rangle$ 和 $\langle v_j \rangle$ 上下波动，即取最近发放历史上的运行平均值。

- 通过考虑不同的突触增强和抑制条件，可以得到多种Hebb学习规则的变体。

突触后 活动 v_i	突触前 活动 v_j	标准 Hebb 学习	基于衰减 的Hebb 学习	突触前 门控Hebb 学习	突触后 门控Hebb 学习	协变 规则
ON	ON	+	+	+	+	+
ON	OFF	0	-	0	-	-
OFF	ON	0	-	-	0	-
OFF	OFF	0	-	0	0	+

(1) 协同性

突触前和突触后神经元必须同时活跃，才能发生突触权重变化。

Cells that fire together, wire together

(2) 有界性

如果仅依赖协同性，突触强度会无限增大或始终处于饱和值。因此，在实际的学习规则中，兴奋性突触的权值应处于一个有界的范围 $[0, w_{max}]$ ，其中 w_{max} 表示生化机制实现突触连接可持续性的最大值。在标准的Hebb规则中，当采用软边界的方法来实现有界性时， c_2^{corr} 可以设置为

$$c_2^{corr}(w_{ij}) = \gamma_2(w_{max} - w_{ij})$$

式中常量 $\gamma_2 > 0$ 。因子 $(w_{max} - w_{ij})$ 是一种软边界的实现，当权值越接近权值上界时，LTP诱导对突触权值变化的影响越小。

(2) 有界性

另外，当采用硬边界，参数可以设置为


$$c_2^{corr}(w_{ij}) = \eta_0 H(w_{max} - w_{ij})$$

其中H是Heaviside阶跃函数。当 $w_{ij} < w_{max}$ 时， c_2^{corr} 为常量；

当 $w_{ij} = w_{max}$ 时，则停止增长。


(3) 竞争性

竞争性是 Hebb 学习规则中的一个核心特性，体现了突触权值之间的动态平衡机制。其基本思想是，当某些权值因神经元活动的相关性而增强时，其余权值必须相应减少，以保持整体的稳定性。





(3) 竞争性

竞争性确保了有限的突触资源能够集中分配给最具影响力的输入信号，从而提升网络的学习效率和信息表示能力。实现竞争性的常用方法是，对突触权值集合进行归一化处理，通过限制权值的总和保持不变，避免权值的无限制增长。



思考题



Assume 2 groups of 10 neurons each. BCM rule with all weights initially equal 1.

Theta=20Hz; output rate given by (*). If one group fires, the other is silent.

a) Group 1 fires at 3 Hz, then group 2 at 1 Hz. Then again group 1 at 3Hz, etc

b) Group 1 fires at 3 Hz, then group 2 at 2.5 Hz. Then again group 1 at 3Hz, etc

c) As in b, but make theta a function of the averaged rate.

What happens?

☐ in a) all weights increase

☐ in a) some weights increase, while others decrease

☐ in b) all weights increase

☐ in b) some weights increase, while others decrease

☐ in c) some weights increase while others decrease

脉冲神经网络的无监督学习

- Hebb学习规则
- STDP学习规则

STDP与Hebb规则关系

- 传统的 Hebb 学习规则通常基于神经元的脉冲频率来更新突触权值。
- 然而，仅依赖脉冲频率并不能完全反映突触可塑性的实际作用机制。
- 神经科学研究发现，突触效能的改变方向和幅度还与神经元发放脉冲的精确时序密切相关。这种考虑突触前后神经元脉冲时间相关性的可塑性，被称为脉冲时间依赖性可塑性（STDP）。
- STDP 是对 Hebb 理论的时间依赖扩展，强调了神经元脉冲时序的因果关系对突触可塑性的作用

实验发现

STDP的最早发现可以追溯到20世纪末的一系列神经科学研究，虽然其核心思想与 Hebb 理论的“用进废退”原则一脉相承，但 STDP 是通过实验直接证实了神经元脉冲时序对突触权值变化的特异性影响。

1988 年，毕国强和蒲慕明通过实验验证了STDP 的存在，并提供了STDP时间窗口的实验依据。具体而言，他们绘制了与突触前后活动和突触变化相关的完整时间过程，并精确描绘了突触强度变化随脉冲时序差值的变化关系：


实验发现

当突触前神经元在突触后神经元激活前的 20 毫秒时间窗内反复激活，会诱导长时程增强（LTP），而突触前神经元在突触后神经元激活后的 20 毫秒时间窗内反复激活，则会诱导长时程抑制（LTD）。


实验发现

若突触前神经元的脉冲在突触后神经元的脉冲前几毫秒产生时，也就是 $t^{pre} < t^{post}$ ，则连接两个神经元的突触权重会增大。相反，当 $t^{pre} > t^{post}$ 时，连接两个神经元的突触权重会减小。实验结果反映了精确的脉冲发放时间的重要性，突触前后神经元放电的相对时间决定了突触变化的方向和程度。

实验发现



假设从突触前神经元 j 到突触后神经元 i 的突触连接权重为 w_{ij} ，用 t_j^f 表示突触前神经元 j 发放脉冲到达突触后神经元 i 的时间，同理用 t_i^f 表示突触后神经元 i 的发时间，在 STDP 学习规则中，突触权重变化 Δw_{ij} 取决于突触前脉冲到达 t_j^f 和突触后发放脉冲 t_i^f 之间的相对时间差。相对时间对突触权重变化的影响体现了 STDP 的两大核心原理：时间因果性和时间窗口。



(1) 时间因果性：指的是突触前后神经元脉冲发放的先后顺序决定了突触权值增强或减弱。当突触前脉冲在突触后脉冲前几毫秒重复到达时 ($t_i^f - t_j^f > 0$)，突触权值会显著增加，即产生长时程增强 (LTP)，而突触后脉冲在突触前脉冲前几毫秒重复到达时 ($t_i^f - t_j^f < 0$)，突触权值会显著减少，即产生长时程抑制 (LTD)。

(2) 时间窗口：根据突触前和突触后动作电位的相对时间，绘制的突触变化被称为STDP 函数或时间窗口。时间窗口描述了突触权值随时间差衰减的范围和幅度，其数学形式通常用双指数函数表示，即时间差越小，权值变化越显著，整体呈现对称且非线性的时间窗口特征。STDP 函数随脉冲相对时间的快速变化，表明了毫秒时间尺度上时间编码方案的可能性。

因此，STDP学习规则数学表示如下：

$$\Delta w_{ij} = W(\Delta t) = \begin{cases} A_+ \exp\left(\frac{-\Delta t}{\tau_+}\right) & \text{for } \Delta t > 0 \\ -A_- \exp\left(\frac{\Delta t}{\tau_-}\right) & \text{for } \Delta t < 0 \end{cases}$$

其中，参数 A_+ 和 A_- 分别表示突触变化的最大值， τ_+ 和 τ_- 分别表示时间常数， $\Delta t = t_i^f - t_j^f$ 为突触前后脉冲的时间差。

权重依赖STDP

在传统STDP中，突触权重可能会无限增长或减小，导致网络不稳定。然而，实验研究表明，突触权重的变化幅度并非固定不变，而是与当前权重大小密切相关。基于这一发现，权重依赖的STDP对经典STDP规则进行了扩展，引入了突触权重大小对可塑性变化的主动调控机制，即根据当前权重值动态调整权重变化的幅度，从而实现更稳定且生物合理的突触更新。

权重依赖STDP

权重依赖的STDP可以通过将参数 A_+ 和 A_- 添加权重约束来实现，按照权重约束的形式分为硬边界和软边界形式，硬边界对突触权重设定明确的上下限 $[w^{min}, w^{max}]$ ，当权重未达到边界时，以固定参数 η_+ 和 η_- 进行更新，达到边界时，无论输入如何，权重均不会再发生变化，公式表示为：

$$A_+(w_{ij}) = \Theta(w^{max} - w_{ij})\eta_+$$

$$A_-(w_{ij}) = \Theta(w_{ij} - w^{min})\eta_-$$

其中 $\Theta(x)$ 表示Heaviside 阶跃函数 $\begin{cases} 1, & x \geq 0 \\ 0, & x < 0 \end{cases}$


权重依赖STDP

硬边界可能导致权重在边界附近“饱和”，显著影响突触的动态调节能力。而软边界使权重逐渐趋于上下限，但不会完全固定。较大的权重增长速度会减慢，而较小的权重减小速度会逐渐变缓，公式表示为：

$$A_+(w_{ij}) = (w^{max} - w_{ij})\eta_+$$

$$A_-(w_{ij}) = (w_{ij} - w^{min})\eta_-$$

权重依赖的 STDP 通过引入突触权重对变化幅度的调节机制，限制权重的上下界，解决了传统 STDP 的权重发散问题，在突触连接的增强（LTP）和减弱（LTD）之间实现更精细的动态平衡，并更贴近生物学神经元真实的可塑性规律。



在线STDP

在神经网络模型中，突触前后神经元会持续发放大量脉冲，每一对脉冲均会通过 STDP 机制对突触权重产生调控作用。若按照下式考虑每对突触前后脉冲的具体作用，直接记录所有脉冲的时序关系，会导致计算和存储上的高昂开销。