

认知科学与类脑计算

主讲教师：刘千惠

联系方式：qhliu@sdu.edu.cn

山东大学 人工智能学院



权重依赖STDP

权重依赖的STDP可以通过将参数 A_+ 和 A_- 添加权重约束来实现，按照权重约束的形式分为硬边界和软边界形式，硬边界对突触权重设定明确的上下限 $[w^{min}, w^{max}]$ ，当权重未达到边界时，以固定参数 η_+ 和 η_- 进行更新，达到边界时，无论输入如何，权重均不会再发生变化，公式表示为：

$$A_+(w_{ij}) = \Theta(w^{max} - w_{ij})\eta_+$$

$$A_-(w_{ij}) = \Theta(w_{ij} - w^{min})\eta_-$$

其中 $\Theta(x)$ 表示Heaviside 阶跃函数 $\begin{cases} 1, & x \geq 0 \\ 0, & x < 0 \end{cases}$

权重依赖STDP

硬边界可能导致权重在边界附近“饱和”，显著影响突触的动态调节能力。而软边界使权重逐渐趋于上下限，但不会完全固定。较大的权重增长速度会减慢，而较小的权重减小速度会逐渐变缓，公式表示为：

$$A_+(w_{ij}) = (w^{max} - w_{ij})\eta_+$$


$$A_-(w_{ij}) = (w_{ij} - w^{min})\eta_-$$

在线STDP

在神经网络模型中，突触前后神经元会持续发放大量脉冲，每一对脉冲均会通过 STDP 机制对突触权重产生调控作用。若按照下式考虑每对突触前后脉冲的具体作用，直接记录所有脉冲的时序关系，会导致计算和存储上的高昂开销。

在线STDP

在线 STDP通过对突触前后神经元脉冲序列的迹（trace）来实现。迹描述了脉冲历史活动的累积效应。每次突触前或突触后神经元发放脉冲时，对应的迹变量都会增加一个固定值（通常为 1），而在没有脉冲输入时，迹变量会依据对应的时间常数呈指数形式逐渐衰减。



在线STDP

突触前后脉冲序列的迹 x_j 和 y_i 表示如下·


$$\tau_+ \frac{dx_j}{dt} = -x_j + \delta(t - t_j^f)$$

$$\tau_- \frac{dy_i}{dt} = -y_i + \delta(t - t_i^f)$$

基于迹的在线STDP学习规则可表示为:

$$\Delta w_{ij}(t)$$

$$= A_+ * x_j(t) * \delta(t - t_i^f) - A_- * y_i(t) * \delta(t - t_j^f)$$



突触前脉冲到达引起的突触权值减小与突触后脉冲迹 y_i 成比例；突触后脉冲发放引起的权值增加与突触前脉冲迹 x_j 成比例。

在线STDP

‘基于迹的在线 STDP 学习规则’与‘原始基于脉冲对独立计算的 STDP 学习规则’是等价的，具体推导如下：

假设突触前神经元和突触后神经元仅发放一次脉冲，脉冲发放时刻分别为 t_j^f 和 t_i^f ，且 $(t_j^f < t_i^f)$ 。求解 x_j 的动力学方程可知，突触前脉冲轨迹呈指数衰减

$$\tau_+ \frac{dx}{dt} = -x_j \xrightarrow{\text{求解}} x_j(t) = \exp\left(-\frac{t-t_j^f}{\tau_+}\right)$$

在线STDP

t_i^f 时刻的输入脉冲迹可以写成如下表达式:

$$x_j(t_i^f) = \exp\left(-\frac{t_i^f - t_j^f}{\tau_+}\right)$$

t_i^f 时刻的在线STDP的突触更新公式为:

$$\Delta w_{ij}(t) = A_+ * x_j(t) * \sum_f \delta(t - t_i^f) - A_- * y_i(t) * \sum_f \delta(t - t_j^f)$$



$$\Delta w_j(t_i^f) = A_+ * x_j(t_i^f) * \sum_f \delta(0) - A_- * y_i(t_i^f) * \sum_f \delta(t_i^f - t_j^f)$$

由于实际计算中脉冲函数为阶跃形式:

$$\delta(t) = \begin{cases} 1, & t = 0 \\ 0, & t \neq 0 \end{cases}$$

在线STDP

$$\Delta w_j(t_i^f) = A_+ * x_j(t_i^f) * \sum_f \delta(0) - A_- * y_i(t_i^f) * \sum_f \delta(t_i^f - t_j^f)$$

由于实际计算中脉冲函数为阶跃形式：

$$\delta(t) = \begin{cases} 1, & t = 0 \\ 0, & t \neq 0 \end{cases}$$

因此，突触更新公式简化为

$$\Delta w_j(t_i^f) = A_+ * x_j(t_i^f) - 0 = A_+ * \exp\left(-\frac{t_i^f - t_j^f}{\tau_+}\right)$$

三元STDP

- 每个突触维护一个突触前迹 a_{pre} 和两个突触后迹 a_{post} 和 a_{post2} 。
- 每当一个突触前脉冲到达该突触时， a_{pre} 被赋值为 1；否则， a_{pre} 会按指数形式衰减。

$$\tau_{a_{pre}} \frac{da_{pre}}{dt} = -a_{pre}$$

- 突触后迹 a_{post} 和 a_{post2} 的工作方式与突触前迹相同，只不过它们的赋值由突触后脉冲触发，并以各自时间常数进行衰减。


三元STDP

When a presynaptic spike arrives at the synapse, the weight is updated based on the postsynaptic trace:

$$\Delta w = A^- a_{\text{post}}$$

When a postsynaptic spike arrives at the synapse, the weight change is

$$\Delta w = A^+ a_{\text{pre}} a_{\text{post2}}$$



三元STDP

When a presynaptic spike arrives at the synapse, the weight is updated based on the postsynaptic trace:

$$\Delta w = A^- a_{\text{post}}$$

When a postsynaptic spike arrives at the synapse, the weight change is

$$\Delta w = A^+ a_{\text{pre}} a_{\text{post}2}$$

Since the weights are not restricted in a range, weight normalization, which keeps the sum L of the synaptic weights connected to each learning neuron unchanged, is used to ensure equal use of the neurons

$$\hat{w}_{ij} = \frac{w_{ij}}{\sum_{k=1}^{n_e} w_{kj}} L$$

1. 快速响应特性

在许多现实场景中，生物体需要快速对潜在的有害刺激做出反应：


当道路上出现障碍时，需在发生碰撞前及时避开；

骑自行车时，需在倾斜角度较小时就进行纠正，而不是等到摔倒后才调整方向。




这种预测性反应能力，可通过 STDP 规则在神经网络中模拟实现。具体而言，STDP 通过动态调整突触权重，使突触前后神经元的时间相关性得到优化，从而让突触后神经元能够在输入信号到来后更快地发放脉冲。

以单个接收来自20个突触前神经元输入为实验模型，来研究STDP的快速反应特性。

实验设置如下：每个突触前神经元仅提供单次脉冲输入，且相邻输入神经元脉冲间隔为3 ms，所有突触的初始权重取值均相同。经过STDP规则训练后，分别记录第1次迭代、第50次迭代和第100次迭代时，突触后神经元的膜电位曲线。



随着训练次数的增加，脉冲发放时间靠近突触后脉冲、且稍早于突触后脉冲’的突触前神经元，其对应的突触权重显著增强；其余突触的权重则被抑制。这种权重的选择性调节，可使突触后神经元的膜电位能够更快地累积，进而逐渐提前达到脉冲发放阈值，最终使突触后神经元的脉冲发放时间显著提前。这一结果表明，STDP 通过强化时序相关的输入模式，可以显著提高突触后神经元的快速反应能力。



2. 时间精度特性

对于时间精度较高的脉冲（即具有明确时间相关性的输入），STDP 会择性增强其对应的突触连接（LTP）；相反，对于时间精度较低或随机分布的脉冲，其对应的突触权重会逐渐减弱（LTD）。这种选择性调节机制，在降低背景噪声干扰的同时，还能显著提升突触后神经元脉冲发放的时间精度，进而使神经网络对动态输入信号的处理更高效、更精准。


2. 时间精度特性

例如，STDP机制解释了哺乳动物初级视觉皮层 V1 神经元对运动方向和速度的响应现象：当物体穿过视野时，视网膜感光细胞按时间顺序激活突触前神经元，STDP则选择性强化与该运动模式时序匹配突触连接。当物体再次以类似速度和方向移动时，突触后神经元能更快、更精准地发放脉冲，从而有效检测运动方向。

思考题



题目一：



We assume a pair-based STDP model formulated with traces:


- ☐ For pre-before-post the decay of the STDP window is exponential with time constant τ_+
- ☐ For pre-before-post the decay is a double exponential with time constants τ_+ AND τ_-
- ☐ For pre-before-post the decay of the STDP window is exponential with time constant τ_-
- ☐ The integral over the STDP window is always positive

题目二：写出在（1）标准Hebb规则，（2）基于衰减的Hebb规则，（3）突触前门控Hebb规则，（4）突触后门控Hebb规则以及（5）协变规则下，不同的突触前后活动组合产生的突触权重改变情况。

重复脉冲模式检测要求从稠密脉冲序列中检测出隐藏的重复时空模式。研究发现，即使突触前神经元以恒定的群体发放率连续发放脉冲，网络中的神经元仍可通过STDP在干扰性噪声脉冲中定位嵌入的重复时空模式。

具体而言，STDP 通过选择性强化那些总是较早发放脉冲的突触输入，将突触权重集中分配到与关键时空模式相关的输入通道上。这一权重优化过程显著缩短了突触后神经元的潜伏期，使其对重复模式的响应时间逐渐缩短，直至达到最小且稳定的状态。

单个模式，单个神经元




构建一个具有100个输入神经元和1个输出神经元的脉冲神经网络，输入输出神经元通过 100×1 的突触权重连接。模型的输入由100个突触前神经元组成，这些神经元的脉冲活动包含随机背景噪声和嵌入的目标时空模式两部分。

STDP无监督学习的应用



山东大学
SHANDONG UNIVERSITY




同时背景噪声和具有时空关联的目标模式，可用于评估网络对稀疏重复时空模式的检测与学习能力

- 蓝色脉冲：背景噪声通过泊松过程生成，瞬时发放率在0到90 Hz 之间随机变化，为模型提供随机性输入环境。
- 红色脉冲：多个持续50毫秒的重复时空模式。每个模式涉及100个输入神经元中的50个神经元，这些神经元按特定时间顺序与空间分布发放脉冲。

STDP无监督学习的应用




输入神经元的发放率均未表现出明显可区分特征。因此，检测该模式需要考虑脉冲的精确时序信息。




STDP无监督学习的应用



模拟开始时，神经元是非选择性的。因为突触的权值都是相等的，输出神经元周期性地发放。




在13.5 s后，大约70次目标模式刺激后，输出神经元出现选择性，只在目标模式出现的窗口内发放脉冲。




一旦神经元对目标模式产生选择性，STDP 会带来另一个显著效果：每当该神经元在目标模式出现时发放脉冲，会进一步强化其与‘模式中稍早发放脉冲的突触前神经元’之间的连接。这样神经元不仅更容易对其做出响应，还会更早发放脉冲。


这种延迟缩短并不会无限进行，当模式中所有早于突触后脉冲的输入突触已经被最大程度强化，且这些输入刚好足够达到发放阈值时，系统会达到收敛状态。此时，神经元对模式的响应时间不再缩短，形成一种由突触饱和引起的稳定发放状态。



如果有三个突触后神经元。在没有抑制的情况下，这三个神经元是独立的；因此，它们的行为与我们之前的研究中完全相同。具体来说，它们都学会了检测重复模式，并沿着模式回溯，直到找到其起始点。



在输出神经元之间引入竞争机制，通过神经元之间的抑制性连接来实现：当一个神经元对某一模式产生响应并发放脉冲时，它会抑制其他神经元发放脉冲。这种机制被称为“赢者通吃”（Winner-Take-All, WTA）机制。



网络中所有兴奋性突触的权重初始化为随机值，且随机值服从 $[0,1]$ 区间的均匀概率分布。输出神经元之间存在侧向抑制连接，当任意一个输出神经元发放脉冲时，会向其他神经元发送强烈的抑制性突触后电位（IPSP）。


与兴奋性连接不同，输出神经元间的侧向抑制连接权重是固定值，不具备可塑性。

基于侧向抑制连接，该模型既可以进行单模式学习，也可以进行多模式学习。

单模式，多个神经元




当用多个输出神经元学习单个重复模式时，受侧向抑制连接的作用，每当一个神经元发放脉冲时，它会向其他神经元发送IPSP，这一抑制作用可避免多个神经元在时间上过于接近地发放脉冲。经过STDP训练后，三个神经元都对目标模式产生了选择性响应，但彼此有不同程度的突触后脉冲时延。




多模式，多个神经元



输入神经元的脉冲序列由独立的泊松过程生成，模拟时间持续数百秒。在这些随机脉冲序列中，以随机时间间隔插入了几个不同的重复时空模式。每个重复模式仅涉及一半的输入神经元，这些神经元是通过独立随机选择确定，因此，不同模式所选定的神经元可能存在重叠，即单个输入神经元可能参与多个模式的构成。



多模式，多个神经元



重复模式的脉冲发放率与背景噪声大致相同，因此无法通过发放率的差异直接区分，检测该模式需要依赖精确脉冲时序信息，而非单纯基于发放率特征。


当用多个输出神经元学习多个重复模式时，在侧向抑制连接与 STDP 的协同作用下，输出神经元会被驱动至仅对某一种特定时空模式产生响应，而对其他时空模式保持静默的状态。

多模式，多个神经元



山东大学
SHANDONG UNIVERSITY

学习3种模式的9个神经元的响应脉冲时延结果



手写数字识别




MNIST包含70,000张手写数字图像:

60,000张用于训练

10,000张用于测试


图像是灰度的, 28x28像素。

手写数字识别




输入层：28×28个神经元
处理层：兴奋性神经元以及抑制性神经元。

手写数字识别



输入以Poisson分布脉冲序列的形式在350毫秒内呈现给网络，发放率与MNIST图像像素的强度成比例。


手写数字识别



侧向抑制，
导致兴奋性神经元之
间的竞争

这些泊松脉冲序列以全连接的方式作为兴奋性神经元的输入。兴奋性神经元通过一对一连接与抑制性神经元连接，每个抑制性神经元都连接到所有兴奋性神经元，除了它接收连接的那个。

手写数字识别






网络不接收类别标签，因此学习是无监督的。训练后，兴奋性神经元根据其对训练集上某个数字类别的最高平均响应被分配到不同的类别。

STDP无监督学习的应用



山东大学
SHANDONG UNIVERSITY

手写数字识别



兴奋性神经元权重可视化

兴奋性神经元个数与准确率的关系


训练样本个数与训练准确率的关系

STDP无监督学习的应用




山东大学
SHANDONG UNIVERSITY

手写数字识别



混淆矩阵



Incorrectly classified digits

错误样本