

认知科学与类脑计算

主讲教师：刘千惠

联系方式：qhliu@sdu.edu.cn

山东大学 人工智能学院





脉冲神经网络监督学习算法

脉冲神经网络（Spiking Neural Networks, SNNs）因其高效的时间动态特性和生物启发的事件驱动机制，成为类脑计算和神经形态工程领域的重要研究方向。然而，与经典人工神经网络（Artificial Neural Networks, ANNs）对比，SNN的训练难度显著增加，尤其在监督学习场景下，如何高效地学习突触权重和时序特征成为亟待解决的问题。

脉冲神经网络监督学习算法

- 经典人工神经网络的学习算法回顾
- 单层脉冲神经网络的学习算法
- 深度脉冲神经网络的学习算法
- 转换算法（ANN-SNN Conversion）

- 反向传播算法是一种用于训练人工神经网络的核心算法，通过计算损失函数对网络参数的梯度，再基于梯度下降的方法来更新网络参数，从而使网络逐渐收敛到损失函数的最小值。
- 反向传播算法主要包括前向传播和反向传播两个步骤。

前向传播：首先，将预处理后的输入数据输入到网络中，通过网络的前向传播过程，计算出网络的输出结果。在这个过程中，每一层的神经元会接收上一层的输出，并经过激活函数非线性变化，计算得到本层的输出并传递到下一层。

反向传播：根据网络的输出和实际标签之间的差异，计算出损失函数，并进一步求解损失函数对网络参数的梯度。随后，沿输出层→隐藏层→输入层的反向方向逐层传递梯度，通过链式法则递归计算每一层参数的梯度，明确各参数对损失的贡献程度。最后，利用梯度下降或其变种优化算法，按梯度方向更新参数，使损失函数值逐步减小，实现网络误差的迭代优化。

传统梯度下降算法是最基础的优化算法之一，它根据损失函数对参数的梯度进行更新，使得损失函数逐渐减小。传统梯度下降算法的更新规则如下

$$\theta_{(t+1)} = \theta_t - \alpha \nabla J(\theta_t)$$

其中：

- θ_t 是第t次迭代时的参数向量。
- α 是学习率，控制参数更新的步长。
- $\nabla J(\theta_t)$ 是损失函数 J 关于参数 θ_t 的梯度。

传统梯度下降算法每次使用全部的训练样本来计算损失函数的梯度，因此在大数据集上的计算量较大，收敛速度较慢。


SGD (Stochastic Gradient Descent) 是一种随机梯度下降算法，它每次只使用一个样本（或者一个小批量样本）来计算损失函数的梯度，并根据这个梯度对参数进行更新。SGD的参数更新规则与传统梯度下降算法一致，但是由于每次只考虑一个样本，因此更新具有一定的随机性。SGD的更新规则如下：

$$\theta_{t+1} = \theta_t - \alpha \nabla J(\theta_t)$$


其中， $\nabla J(\theta_t)$ 是针对当前随机选取的一个样本计算的梯度。

SGD的随机性使得它可以更快地收敛，并且在大数据集上更加高效，但训练过程也可能导致更新的不稳定性。


实例推导：



实例推导：




实例推导：




随机初始化: $w_1 = 0.5, w_2 = 1.5, w_3 = 2.3, w_4 = 3,$
 $w_5 = 1, w_6 = 1,$

实例推导：




实例推导：



首先计算前向传播，即预测 h_1, h_2, y 和误差项 E ，其中 $E = \frac{1}{2}(t - y)^2$


实例推导：



$$h_1 = w_1 \cdot x_1 + w_2 \cdot x_2 = 1.25$$

$$h_2 = w_3 \cdot x_1 + w_4 \cdot x_2 = 3.8$$

实例推导：




$$h_1 = w_1 \cdot x_1 + w_2 \cdot x_2 = 1.25$$

$$h_2 = w_3 \cdot x_1 + w_4 \cdot x_2 = 3.8$$

$$y = w_5 \cdot h_1 + w_6 \cdot h_2 = 5.05$$


实例推导：



下面开始误差反向传播。根据网络的输出和实际标签之间的差异，计算出损失函数 E ，以求解损失函数对网络参数的梯度。

$$E = \frac{1}{2}(y - t)^2 = 0.55125$$

实例推导：



要更新 w_5 的值，根据链式法则需要计算：

$$\frac{\partial E}{\partial w_5} = \frac{\partial E}{\partial y} \cdot \frac{\partial y}{\partial w_5}$$

实例推导:

$$\frac{\partial E}{\partial w_5} = \frac{\partial E}{\partial y} \cdot \frac{\partial y}{\partial w_5}$$

因为 $E = \frac{1}{2}(t - y)^2$, 所以

$$\begin{aligned}\frac{\partial E}{\partial y} &= 2 \cdot \frac{1}{2} \cdot (t - y) \cdot (-1) \\ &= y - t \\ &= 5.05 - 4 = 1.05\end{aligned}$$

而 $y = w_5 * h_1 + w_6 * h_2$, 所以

$$\frac{\partial y}{\partial w_5} = h_1 + 0 = h_1 = 1.25$$

把上面两项相乘我们得到

$$\begin{aligned}\frac{\partial E}{\partial w_5} &= \frac{\partial E}{\partial y} \cdot \frac{\partial y}{\partial w_5} = (y - t) \cdot h_1 \\ &= 1.05 \cdot 1.25 = 1.3125\end{aligned}$$


实例推导：

假设学习率为0.1，

$$\begin{aligned}w_5^+ &= w_5 - \alpha \cdot \frac{\partial E}{\partial w_5} \\&= 1 - 0.1 \cdot 1.3125 \\&= 0.86875\end{aligned}$$

我们可以按照相同的步骤更新 w_6

实例推导：



下面我们再来看 w_1, w_2, w_3, w_4 ，由于这四个参数在同一层，所以求梯度的方法是相同的。这里仅展示对 w_1 的推导：

$$\frac{\partial E}{\partial w_1} = \frac{\partial E}{\partial y} \cdot \frac{\partial y}{\partial h_1} \cdot \frac{\partial h_1}{\partial w_1}$$

实例推导:

$$\frac{\partial E}{\partial w_1} = \frac{\partial E}{\partial y} \cdot \frac{\partial y}{\partial h_1} \cdot \frac{\partial h_1}{\partial w_1}$$

其中 $\frac{\partial E}{\partial y} = y - t$ 在求 $\frac{\partial E}{\partial w_5}$ 的时候已经求过了。而根据 $y = w_5 \cdot h_1 + w_6 \cdot h_2$ 我们可以得到

$$\frac{\partial y}{\partial h_1} = w_5 + 0 = w_5$$

又根据 $h_1 = w_1 \cdot x_1 + w_2 \cdot x_2$ 我们可以得到

$$\frac{\partial h_1}{\partial w_1} = x_1 + 0 = x_1$$

因此我们有下面的公式

$$\frac{\partial E}{\partial w_1} = (y - t) \cdot w_5 \cdot x_1$$


实例推导：

现在我们代入数字并使用梯度下降法更新 w_1

$$\begin{aligned}w_1^+ &= w_1 - \alpha \cdot \frac{\partial E}{\partial w_1} \\&= w_1 - \eta \cdot (y - t) \cdot w_5 \cdot x_1 \\&= 0.5 - 0.1 \cdot 1.05 \cdot 1 \cdot 1 \\&= 0.395\end{aligned}$$

然后重复这个步骤更新 w_2, w_3, w_4

思考题



已知首次前向传播结果为：

$$\begin{aligned} h_1 &= w_1 \cdot x_1 + w_2 \cdot x_2 = 1.25 & y &= w_5 \cdot h_1 + w_6 \cdot h_2 = 5.05 \\ h_2 &= w_3 \cdot x_1 + w_4 \cdot x_2 = 3.8 & E &= \frac{1}{2}(y - t)^2 = 0.55125 \end{aligned}$$

问题：设学习率为0.1，请完成以下任务：

- (1) 推导并计算权重 $w_1, w_2, w_3, w_4, w_5, w_6$ 的梯度；
- (2) 根据梯度下降法更新各权重参数；
- (3) 使用更新后的参数重新进行一次前向传播；
- (4) 计算新的损失函数值 E ；
- (5) 说明新的损失是否低于初始损失0.55125，判断学习是否有效

单层脉冲神经网络是脉冲神经网络中最基础的结构形式，尽管其网络层次较浅、可学习参数规模有限，但在时空信息处理和事件驱动任务中依然展现出显著的优势。单层SNN的核心在于：利用脉冲神经元对时间和脉冲强度的敏感性，通过监督或无监督学习机制动态调整突触连接权重，以捕捉输入数据的时空特征，实现任务目标。

电压驱动的单层Tempotron学习算法

Tempotron 是一种经典的脉冲神经网络学习算法，核心目标是解决基于时间编码的模式识别任务。Tempotron 的核心思想是利用基于膜电位的动态演化，将输入脉冲序列映射到神经元的膜电位峰值上，并通过监督学习规则（例如梯度下降法）调整突触权重，使目标模式能够引发神经元的发放，而非目标模式则不会引发发放。

电压驱动的单层Tempotron学习算法

为了利用单个脉冲神经元来学习区分不同的时间序列输入模式，Tempotron算法使用了一种基于电流响应的脉冲神经元模型，其膜电位动态演化公式如下：

$$V(t) = \sum_i \omega_i \sum_{t_i} K(t - t_i) + V_{rest},$$

$$K(t - t_i) = \begin{cases} V_0 [\exp(-(t - t_i)/\tau) - \exp(-(t - t_i)/\tau_s)] & t \geq t_i \\ 0 & t < t_i \end{cases}$$

$K(t - t_i)$ 用于描述每个输入脉冲引起的突触后电位（PSP），考虑了两个指数衰减项，一项与膜的积分时间常数 τ 相关，另一项与突触电流的衰减时间常数 τ_s 相关

二分类任务场景下Tempotron算法

考虑使用单个脉冲神经元实现二分类任务的场景，若输出神经元发放脉冲，预测类别为 1；若不发放脉冲，预测类别为 0。

针对属于类别1的样本，如果输出神经元发放脉冲，那么无需调整。反之，如果输出神经元没有发放，Tempotron算法则通过找到最大膜电位 $V(t_{\max})$ 并增加权重以增加 $V(t_{\max})$ ，使其超过发放阈值从而修正预测。

二分类任务场景下Tempotron算法

- 若神经元发放脉冲:

$$y = 1$$

- 若未发放:

$$y = 0$$

神经元是否发放由:

$$\max_t V(t) \geq V_{\text{thr}} \quad \text{决定。}$$

因此:

- 正样本（应该发放）:

希望

$$V(t_{\text{max}}) > V_{\text{thr}}$$

- 负样本（不应发放）:

希望

$$V(t_{\text{max}}) < V_{\text{thr}}$$

二分类任务场景下Tempotron算法

对于正样本：

希望：

$$V(t_{\max}) > V_{\text{thr}}$$

如果没有达到：

$$V(t_{\max}) < V_{\text{thr}}$$

就产生误差。

因此定义：

$$E_+ = \frac{1}{2}(V_{\text{thr}} - V(t_{\max}))^2$$

但只有在：

$$V_{\text{thr}} - V(t_{\max}) > 0 \quad \text{时才需要更新。}$$

因此需要乘：

$$\Theta(V_{\text{thr}} - V(t_{\max}))$$

得到：

$$E_+ = \frac{1}{2}(V_{\text{thr}} - V(t_{\max}))^2 \Theta(V_{\text{thr}} - V(t_{\max}))$$

二分类任务场景下Tempotron算法

对于负样本:

希望:

$$V(t_{\max}) < V_{\text{thr}}$$

若:

$$V(t_{\max}) > V_{\text{thr}}$$

说明错误发放。

因此误差方向相反定义:

$$E_- = -\frac{1}{2}(V_{\text{thr}} - V(t_{\max}))^2 \Theta(-(V_{\text{thr}} - V(t_{\max})))$$

二分类任务场景下Tempotron算法

$$E_+ = \frac{1}{2}(V_{\text{thr}} - V(t_{\text{max}}))^2 \Theta(V_{\text{thr}} - V(t_{\text{max}}))$$

$$E_- = -\frac{1}{2}(V_{\text{thr}} - V(t_{\text{max}}))^2 \Theta(-(V_{\text{thr}} - V(t_{\text{max}})))$$

合并成：

$$E_{\pm} = \pm \frac{1}{2}(V_{\text{thr}} - V(t_{\text{max}}))^2 \Theta(\pm(V_{\text{thr}} - V(t_{\text{max}})))$$

现在对E关于 w_i 求导：

$$\frac{dE}{d\omega_i} = \frac{dE}{dV(t_{\text{max}})} \cdot \frac{dV(t_{\text{max}})}{d\omega_i}$$

二分类任务场景下Tempotron算法

$$\frac{dE}{d\omega_i} = \frac{dE}{dV(t_{\max})} \cdot \frac{dV(t_{\max})}{d\omega_i}$$

由于

$$V(t_{\max}) = \sum_i \omega_i \sum_{t_i < t_{\max}} K(t_{\max} - t_i)$$

得到:

$$\frac{\partial V(t_{\max})}{\partial \omega_i} = \sum_{t_i < t_{\max}} K(t_{\max} - t_i) + \frac{\partial V(t_{\max})}{\partial t_{\max}} \frac{dt_{\max}}{d\omega_i}$$

于是:

$$-\frac{dE}{d\omega_i} = \pm \sum_{t_i < t_{\max}} K(\Delta t_i) \pm \frac{\partial V(t_{\max})}{\partial t_{\max}} \frac{dt_{\max}}{d\omega_i}$$

$$-\frac{dE}{d\omega_i} = \pm \sum_{t_i < t_{\max}} K(\Delta t_i) \pm \frac{\partial V(t_{\max})}{\partial t_{\max}} \frac{dt_{\max}}{d\omega_i}$$

假设最大膜电位时间点 $t_{\max}$ 附近是一个连续可微的极值点

$\frac{\partial V(t_{\max})}{\partial t_{\max}} = 0$ ，那么可得到Tempotron学习规则：

$$\Delta\omega_i = \lambda \sum_{t_i < t_{\max}} K(t_{\max} - t_i)$$

其中最大膜电位时间点 $t_{\max}$ 可以通过离散时间点枚举的方式得到，或者也可通过求电压曲线的极值点得到。

单层脉冲神经网络学习算法



山东大学
SHANDONG UNIVERSITY

