

认知科学与类脑计算

主讲教师：刘千惠

联系方式：qhliu@sdu.edu.cn

山东大学 人工智能学院



脉冲神经网络监督学习算法

- 经典人工神经网络的学习算法回顾
- 单层脉冲神经网络的学习算法
- 深度脉冲神经网络的学习算法
- 转换算法 (ANN-SNN Conversion)

转换算法（ANN-SNN Conversion）

ANN-SNN 转化算法的核心思想是：首先使用反向传播算法训练一个神经网络（ANN），然后将训练好的权重映射到结构等价的脉冲神经网络（SNN）中，而后利用SNN进行推理任务。

ANN中激活函数的激活值可以近似等价于SNN中神经元的脉冲发放速率（Firing Rate）。因此，如果在训练ANN时对输入、权重、激活值等进行适当的约束，便可以实现ANN到SNN的映射，转化完成后，可利用 SNN 的事件驱动特性（仅脉冲发放时耗能），在推理阶段实现低功耗、高效率的信号处理。

ANN-SNN 转换流程

1. 对网络的所有单元使用 ReLU。
2. 在整个训练过程中将偏置固定为零，并使用反向传播进行训练。
3. 将 ReLU 网络的权重直接映射到 IF 单元网络。
4. 使用权重归一化以获得接近无损的精度和更快的收敛速度。

ANN-SNN 转化基本原理

$$\text{ANN中} : \mathbf{a}^l = f\left(\sum w_{ij} \mathbf{a}^{l-1}\right)$$

$$\text{SNN中} : r_{s_i}^{l+1} \approx \frac{\sum_{j=1}^n w_{ij} r_{s_j}^l}{\theta_i}$$

如果我们让上一层 SNN 发放率近似 ANN 激活值:

$$r_s^l \approx a^l$$

并且设置合适的阈值或权重缩放, 那么就可以得到:

$$r_s^{l+1} \approx a^{l+1}$$

阈值过高或权重过低 $W_i r_s^l \ll \theta_i$:

- 可以减少过度发放;
- 可以减轻 spike 非理想性带来的过激活;
- 容易造成激活不足。

阈值过低或权重过高 $W_i r_s^l \gg \theta_i$:

- 减少激活不足;
- 神经元更容易产生 spike;
- 容易过度发放。

解决方法:

- 手动调节每一层的阈值和权重比例
- 计算每层权重的 rescaling factor, 使得 ANN 激活和 SNN 发放率尽量匹配。

基于模型的归一化 Model-Based Normalization

只看网络权重，不需要数据

Algorithm 1: Model-Based Normalization

```
1  for layer in layers:
2      max_pos_input = 0
3      # Find maximum input for this layer
4      for neuron in layer.neurons:
5          input_sum = 0
6          for input_wt in neuron.input_wts:
7              input_sum += max(0, input_wt)
8          max_pos_input = max(max_pos_input, input_sum)
9      # Rescale all weights
10     for neuron in layer.neurons:
11         for input_wt in neuron.input_wts:
12             input_wt = input_wt / max_pos_input
```

归一化后，任何神经元即使在所有正输入 spike 同时到达的最坏情况下，单步输入也不会超过阈值，因此不会需要在一个时间步内表示超过一个 spike。但可能需要更长的时间生成脉冲。

基于数据的归一化 Data-Based Normalization

在真实数据输入下，每一层通常会产生多大的激活。

Algorithm 2: Data-Based Normalization

```

1 | previous_factor = 1
2 | for layer in layers:
3 |     max_wt = 0
4 |     max_act = 0
5 |     for neuron in layer.neurons:
6 |         for input_wt in neuron.input_wts:
7 |             max_wt = max(max_wt, input_wt)
8 |             max_act = max(max_act, neuron.output_act)
9 |     scale_factor = max(max_wt, max_act)
10 |    applied_factor = scale_factor / previous_factor
11 |    # Rescale all weights
12 |    for neuron in layer.neurons:
13 |        for input_wt in neuron.input_wts:
14 |            input_wt = input_wt / applied_factor
15 |    previous_factor = scale_factor
    
```

max_act 控制整体发放率不超过可表示范围，max_wt 防止单个输入 spike 通过过大的权重造成瞬时过强输入；取二者最大值，是同时满足这两个约束的最小安全缩放因子。

$$W^l \leftarrow \frac{W^l}{\text{applied_factor}}$$

$$\text{applied_factor} = \frac{\text{scale_factor}}{\text{previous_factor}} = \frac{\lambda^l}{\lambda^{l-1}}$$

$$W^l \leftarrow W^l \frac{\lambda^{l-1}}{\lambda^l}$$


ANN-SNN 转换

方法	依据	优点	缺点
Model-Based	只看权重最大正输入	安全，无需数据	过于保守，可能发放不足
Data-Based	用训练集统计数据最大激活	精度高，延迟低	依赖训练集代表性

TTFS编码的ANN-SNN 转换

与传统 rate-based ANN-SNN 转换不同，TTFS 转换不是用一段时间窗口内的 spike 数量或平均发放率来近似 ANN 的激活值，而是利用脉冲到达时间来近似ANN 激活值。

在 TTFS coding 中，每个神经元在一个时间窗口内通常只发放一次 spike，激活值越大，对应的首次发放时间越早。这样，TTFS 可以用更少的 spike 表示信息，从而降低计算量和能耗。



TTFs编码的ANN-SNN 转换


ANN 神经元模型

在 ANN 中，神经元仍然是普通的模拟值神经元，其输出由加权求和再经过激活函数得到：

$$a_i^l = f \left(\sum_j w_{ij}^l a_j^{l-1} + b_i^l \right)$$

其中， f 函数不是使用普通 ReLU，而是使用 ReLU1，也就是把激活值限制在 $[0,1]$ 内：

$$f(x) = \begin{cases} 0, & x \leq 0 \\ x, & 0 < x \leq 1 \\ 1, & x > 1 \end{cases}$$



TTFS编码的ANN-SNN 转换

TTFS 用“首次发放时间”表示 ANN 激活值，而一个固定时间窗口只能表示有限范围内的值。所以需要把 ANN 激活值限制到 $[0,1]$ ，才能和 spike time 建立稳定的一一对应关系。

ANN 激活值 α_i^l	SNN spike time t_i^l	含义
1	窗口起点	最大激活，最早发放
0.5	窗口中间	中等激活
0	窗口终点	最小激活，最晚发放

TTFs编码的ANN-SNN 转换

SNN 神经元模型:

转换后的 SNN 使用的膜电位动态定义为:

$$V_i^l(t) = \sum_{j=1}^{N^{l-1}} w_{ij}^l K(t - t_j^{l-1})$$
$$K(t - t_j^{l-1}) = \begin{cases} t - t_j^{l-1}, & \text{if } t > t_j^{l-1} \\ 0, & \text{otherwise.} \end{cases}$$

对于 $t > t_i^{l-1}$ 时,

$$V_i^l(t) = \sum_{j=1}^{N^{l-1}} w_{ij}^l (t - t_j^{l-1}).$$

当膜电位达到阈值 ϑ 时, 当前神经元发放第一次 spike:


$$t_i^l = \mathcal{F} \{t | V_i^l(t) = \vartheta, t \geq 0\} \quad \text{通常把阈值设为1}$$

TTFS编码的ANN-SNN 转换

ANN 激活值和 SNN spike time 的对应关系

$$\frac{t_i^l - t_{\min}^l}{t_{\max}^l - t_{\min}^l} = 1 - a_i^l$$

- $\alpha_i^l=1$: 最早发放;
- $\alpha_i^l=0$: 最晚发放;
- 激活值越大, spike time 越靠前。




如果每一层的时间窗口长度设为 $T=1$, 则可以写成:

$$t_i^l = l + 1 - a_{i,n}^l$$

就建立了 ANN 激活值和 SNN 首次发放时间之间的对应关系。

TTFS编码的ANN-SNN 转换 过早放电问题



(a) 对于人工神经网络 (ANN), 来自神经元 A 和 B 的净输入之和为 0, 导致神经元 C 保持不激活状态。

(b) 对于脉冲神经网络 (SNN), 经过 TTFS 转换后, 来自神经元 A 的早期放电会导致神经元 C 在 $t = 0.4$ 时发出“过早”放电, 此时, 来自神经元 B 的抑制输入尚未到达。

TTFS编码的ANN-SNN 转换

漏放电问题

ANN 中多个较小的正输入加起来应该让神经元激活，但转换成 TTFS-SNN 后，这些 spike 在给定时间窗口内不足以让膜电位达到阈值，导致神经元没有发放。

ANN 中：

$$0.2+0.2+0.2+0.2+0.2=1.0$$

如果激活条件相当于 1，那么它可以直接得到有效激活。

SNN中，假设阈值为1，允许发放时间窗口是[1,2]，五个输入脉冲每个权重都是0.2，并且这些脉冲都是在1.8s才到达。在窗口结束t=2时：

$$V(2) = \sum_{j=1}^5 0.2(2 - 1.8)$$

$$V(2) = 5 \times 0.2 \times 0.2 = 0.2$$

TTFS编码的ANN-SNN 转换

为每一层分配独立的时间窗口：

时间段	第 l 层是否允许发放
$t < lT$	不允许
$lT \leq t < (l+1)T$	允许
$t \geq (l+1)T$	强制处理到边界

通过动态阈值来实现：

$$\vartheta^l(t) = \begin{cases} \infty, & \text{if } t < lT \\ 1, & \text{if } t \in [lT, (l+1)T) \\ -\infty, & \text{if } t \geq (l+1)T. \end{cases}$$

TTFS编码的ANN-SNN 转换

怎么解决过早放电问题？

过早放电问题：正输入先到，负输入后到，神经元在负输入到达前就提前发放。

动态阈值让神经元在窗口开始前不能发放： $\vartheta = \infty$

所以即使早到的正输入已经把膜电位推高，神经元也不会马上 spike。等到进入自己的窗口后，上一层输入基本已经到齐，再根据完整输入决定 spike time。

TTFS编码的ANN-SNN 转换

怎么解决漏放电问题？

漏放电问题：多个较小的输入在 ANN 中相加后可能足够产生激活，但在 TTFS-SNN 中，由于 spike 到达时间分散、窗口有限，膜电位可能没有在规定时间内达到阈值。

动态阈值的窗口设计使得每一层有明确的合法发放区间，并通过窗口末端边界处理：

$$t_i^l = (l + 1)T$$

把没有达到阈值的情况对应 $a_i^l = 0$

TTFS编码的ANN-SNN 转换

时间扭曲问题

在基于TTFS的转换中，理想目标是建立一个简单的一一映射：

$$t_i^l = l + 1 - a_i^l$$

实际 SNN 神经元的 spike time 不只由 ANN 里的加权输入决定，还会受到权重和的影响：

$$\sum_j w_{ij}^l$$

这就导致同样的 ANN 激活值，可能因为不同神经元的权重和不同，被映射成不同的 spike time。

TTFS编码的ANN-SNN 转换

时间扭曲问题

$$V_i^l(t) = \sum_j w_{ij}^l (t - t_j^{l-1})$$

$$V_i^l(t) = \sum_j w_{ij}^l t - \sum_j w_{ij}^l t_j^{l-1}$$

$$V_i^l(t_i^l) = \vartheta \quad t_i^l \sum_j w_{ij}^l - \sum_j w_{ij}^l t_j^{l-1} = \vartheta$$

$$t_i^l \sum_j w_{ij}^l = \vartheta + \sum_j w_{ij}^l t_j^{l-1}$$

$$t_i^l = \frac{\vartheta + \sum_j w_{ij}^l t_j^{l-1}}{\sum_j w_{ij}^l}$$

TTFS编码的ANN-SNN 转换

时间扭曲问题

$$t_i^l = \frac{\vartheta + \sum_j w_{ij}^l t_j^{l-1}}{\sum_j w_{ij}^l}$$

把 $t_j^{l-1} = l - a_j^{l-1}$ 代入,

$$t_i^l = \frac{\vartheta + l \times \sum_{j=0}^{N^{l-1}} w_{ij}^l - \sum_{j=0}^{N^{l-1}} w_{ij}^l a_j^{l-1}}{\sum_{j=0}^{N^{l-1}} w_{ij}^l}$$

脉冲时间 t_i^l 取决于加权输入 $\sum_{j=0}^{N^{l-1}} w_{ij}^l a_j^{l-1}$ 和权重和 $\sum_{j=0}^{N^{l-1}} w_{ij}^l$ 。当将激活值 a_j^{l-1} 从模拟神经元传递到脉冲神经元时, 这种对权重和的额外依赖性将导致ANN和SNN输出之间出现显著不匹配。

TTFS编码的ANN-SNN 转换

怎么解决时间扭曲问题

用两步来保证：
$$\sum_j w_{ij}^l = 1$$

Soft constraint

训练 ANN 时加入正则项：

$$L_W = \sum_l \sum_i \left| \sum_j w_{ij}^l - 1 \right|$$

Hard constraint


训练过程中进一步强制修正，使每个神经元的权重和严格等于 1。
原因是：即使权重和只是轻微偏离 1，这种偏差在深层网络中也会逐层累积，最终造成明显的 spike time 偏移。

TTFS编码的ANN-SNN 转换结果


SUMMARY OF THE RESULT OF ABLATION STUDIES. NOTE THAT Δ ACC. REFERS TO THE DIFFERENCE BETWEEN THE PRETRAINED ANNS AND THE CONVERTED SNNs GIVEN IN COLUMNS 7 AND 8, RESPECTIVELY. **SOFT**: SOFT CONSTRAINT FOR WEIGHT SUM; **HARD**: HARD CONSTRAINT FOR WEIGHT SUM; **ReLU1**: ReLU1 ACTIVATION FUNCTION; **NORM**: PREACTIVATION NORMALIZATION; **DYNAMIC**: DYNAMIC FIRING THRESHOLD

Model	Soft	Hard	ReLU1	Norm	Dynamic	ANN (Acc.%)	SNN (Acc.%)	Δ Acc.%
Baseline	✓	✓	✓	✓	✓	91.30	91.25	0.05
1	✗	✗	✗	✗	✗	91.33	10.00	81.33
2a	✓	✗	✓	✓	✓	91.57	86.95	4.62
2b	✗	✗	✓	✓	✓	92.10	29.18	62.92
3	✓	✓	✗	✓	✓	90.87	64.44	26.43
4	✓	✓	✓	✗	✓	89.60	89.67	-0.07
5	✓	✓	✓	✓	✗	91.30	77.82	13.48

TTFS编码的ANN-SNN 转换应用



图像重建



语音增强

转换算法（ANN-SNN Conversion）

对比项	Conversion-based 方法	Direct training 方法
核心思想	先训练 ANN，再转换成 SNN	直接训练 SNN
训练难度	较低	较高
时间动态	没有被充分优化	显式建模并优化
精度表现	如果转换误差小，可以保持较高精度	取决于代理梯度和训练稳定性
生物合理性	较弱	相对更强
适用场景	分类、转换友好的任务	时序任务、事件数据、动态任务

1. 在 STBP 代码中，脉冲发放函数通常写成：

```
def forward(ctx, input):  
    ctx.save_for_backward(input)  
    return input.gt(thresh).float()  
  
def backward(ctx, grad_output):  
    input, = ctx.saved_tensors  
    temp = abs(input - thresh) < lens  
    return grad_output * temp.float()
```

在这段代码中，forward 和 backward 分别实现了什么？为什么不能直接使用真实的阶跃函数导数？

2. 某层 ANN 的最大激活值为： $\lambda^l = 8$

上一层最大激活值为： $\lambda^{l-1} = 2$

ANN 权重为： W^l

在 data-based normalization 中，转换后的 SNN 权重应如何缩放？

3. 请比较 rate-based ANN-SNN 转换和 TTFS-based ANN-SNN 转换的主要区别。

类脑计算应用



山东大学
SHANDONG UNIVERSITY

智能制造科普 bilibili



2026年5月28日晚，比亚迪在深圳举办“敢为”智能化战略发布会。发布会上，比亚迪宣布面向L3/L4的自动驾驶版“天神之眼”平台将首搭闪拍摄像头，

高等级自动驾驶

从「遥不可及」到「指日可待」

天神之眼自动驾驶版（L3/L4） 将首搭超干线激光雷达、闪拍摄像头、双远红外摄像头



公众号 · AlpsenTek锐思智芯


该摄像头“专为高速运动物体捕捉而设计”，以超低延时（ $<1\text{ms}$ ）特性为高阶智驾提供高速动态感知能力(1000fps)。

“当一闪而过电动车一露头的时候，闪拍摄像头就能轻松捕捉，意味着风险还没有发生，系统就已做好了相应的准备”。





神经形态相机



- 光感受器的局部自适应增益控制：感知有高动态范围
- 视杆细胞的空间带通滤波器：滤除冗余和噪声
- ON和OFF脉冲信号编码：提高发放效率
- 感光功能区划分：中央凹（精细纹理）、外周的区域(快速运动)

神经形态相机

理论

探索

商用




图1 神经形态视觉传感器的发展历程，蓝色框为里程碑事件

李家宁, 田永鸿. 神经形态视觉传感器的研究进展及应用综述[J]. 计算机学报, 2021, 44(6): 1258-1286.

神经形态相机

- 视网膜外周感知运动功能的差分型视觉采样模型

DVS、ATIS、DAVIS、CeleX



- 视网膜中央凹感知精细纹理功能的积分型视觉采样模型

章鱼视网膜、Vidar (Spike Camera)

神经形态相机

Consider the intensity at a **single pixel**...

$$\pm C = \log I(x, t) - \log I(x, t - \Delta t)$$





Events are triggered **asynchronously**



Lichtsteiner et al., A 128x128 120 dB 15 μ s Latency Asynchronous Temporal Contrast Vision Sensor, IEEE Journal of Solid-State Circuits, 2008

神经形态相机


- A **traditional camera** outputs frames at **fixed time intervals**:




- By contrast, a **DVS** outputs **asynchronous events** at **microsecond resolution**. An event is generated each time a single pixel detects an intensity changes value




神经形态相机



事件相机：差分型视觉采样



脉冲相机：积分型视觉采样





传统相机、事件相机、脉冲相机对比

神经形态相机


物体追踪与检测

事件相机具有高时间分辨率、高动态范围且仅响应动态信息的优势，可在高速运动、弱光或光照剧烈变化场景下实现更稳定、高效的物体检测与追踪，动作识别与行为分析，同时减少静态背景干扰与数据冗余。



低光下的图像 事件信号 增强后的图像


场景感知增强：极端场景



事件相机可作为传统视觉的有效补充，在弱光、强光、逆光、眩光或高速运动等极端场景下捕捉关键动态变化，补足传统视觉在极端环境下的信息缺失。



神经形态相机

生物神经信号





神经信号特点：
异步、事件驱动

神经网络（低功耗）



脉冲神经网络与传统神经网络的区别：
异步、事件驱动的信息传递方式

传感器（快速、感光范围大）



事件相机与传统相机的区别：
异步、事件驱动的感光方式


事件流编码方法

异步 (asynchronous): 每个事件独立产生, 无全局帧率

稀疏 (sparse): 仅亮度变化处产生事件, 数据量小

高时间分辨率: 微秒级精度, 远超传统相机

每个事件格式: (x, y, t, p)



事件流编码方法


时间计数编码 (Count Encoding)

在固定时间窗口内，统计每个像素位置发生事件的次数（或净次数）。正负极性可分通道表示。

$$C(x, y) = \sum \delta(x - x_i) \delta(y - y_i) \cdot p_i, p_i \in \{+1, -1\}$$

特点

- ▶ 简单、计算快、信息损失大
- ▶ 丢失时间信息
- ▶ 可分正负极性
- ▶ 适用：高速运动检测、快速分类



事件流编码方法


二值事件帧编码 (Binary Event Frame)

只关心像素在窗口内是否有事件发生，不记录次数。有事件为1，否则为0。

$$B(x, y) = 1_{\{(x_i, y_i) = (x, y)\}}, \text{ 输出 } \{0, 1\}$$

特点

- ▶ 信息压缩到极致，极度稀疏高效
- ▶ 动态信息丢失（速度、顺序）
- ▶ 可分两个极性通道
- ▶ 适用：极简嵌入式系统，较少单独使用



事件流编码方法

Time-Surface 编码

用最近事件发生的时间编码每个像素，形成"衰减的记忆图"，像素值反映事件"新鲜度"。

$$S(x, y, t) = \exp\left(-\frac{t - t_{last}(x, y)}{\tau}\right)$$

特点

- ▶ 保留局部时间信息，对运动速度敏感
- ▶ τ 控制衰减速率，可调时间感知窗口
- ▶ 适用：光流估计、特征追踪

事件流编码方法

Time-Surface 编码

用最近事件发生的时间编码每个像素，形成"衰减的记忆图"，像素值反映事件"新鲜度"。


$$S(x, y, t) = \exp\left(-\frac{t - t_{last}(x, y)}{\tau}\right)$$

特点

- ▶ 保留局部时间信息，对运动速度敏感
- ▶ τ 控制衰减速率，可调时间感知窗口
- ▶ 适用：光流估计、特征追踪

语音信号处理


基于SNN的人机听觉接口



HuRAI : Human-Robotic Auditory Interface

语音信号处理

人机听觉接口中的三个子系统：语音命令识别，语音活动检测和声源定位



语音信号处理

STFT (Short-Time Fourier Transform, 短时傅里叶变换) :

将语音信号从时域转换到时频域，得到随时间变化的频谱表示，为后续特征提取提供基础。

Mel-scaled Filter Bank (梅尔滤波器组) :

在 STFT 频谱的基础上进一步提取感知相关特征。由于人耳对低频更加敏感，而对高频的分辨率较低，因此频率轴通常不采用线性划分，而是按照 Mel 尺度进行划分，从而得到更符合人耳听觉特性的 Mel 频带特征。


GCC-PHAT Feature Extraction (广义互相关相位变换特征提取) :

主要用于声源定位任务。它通过分析多麦克风信号之间的相位差和到达时间差，提取与声源方向相关的时延特征，从而帮助模型判断声音来自哪个方向。

Voice Activity Detection (VAD)：语音活动检测

目标是判断当前音频片段中是否有人声。

输出通常是二分类：Voice/Non-voice




Voice Command Recognition: 语音命令识别

语音命令识别的目标是判断用户说的是哪一个固定命令，例如：

Up, Down, Left, Unknown

本质是一个多分类任务。系统需要从一段短语音中识别出命令类别。



Speaker Localization 声源定位


声源定位的目标是判断声音从哪个方向传来。

输出可以是角度类别，例如：


$1^\circ, 2^\circ, 3^\circ, \dots, 360^\circ$

也可以是几个离散方向类别，例如：


front, left, right, back



不同噪音环境下的语音活动检测结果



语音活动检测结果



不同噪音环境下的语音命令识别和声源定位结果

